**UNITE DE FORMATION ET DE RECHERCHE**

**SCIENCE DE L'INGENIEUR**

**LICENCE 2 GEOMATIQUE**

# PROJET : QUALITE DE L'AIR, BRUIT ET MICROCLIMAT A THIES (2025)

**Devoir d'Analyse 3**


**Professeur : Mr Almamy LY**

AWA FAYE

L2 GEOMATIQUE


Date : 10/01/2026

## INTRODUCTION

Ce projet porte sur l’analyse de la qualité de l’air, du bruit et du microclimat dans la ville de Thiès en 2025. À partir de données collectées par des capteurs installés dans différentes zones (urbaines, périurbaines et rurales), l’étude vise à décrire les niveaux de pollution et à analyser leurs liens avec l’usage du sol, la végétation et certaines activités humaines. Les résultats permettront de mieux comprendre les facteurs influençant l’environnement urbain à Thiès.

## 1) Variables (dictionnaire rapide)

- Qualitatives : Type_zone, Usage_sol, Risque_inondation, Qualite_capteur, Brulage_dechets, Localite, Station
- Quantitatives : PM25_ugm3, NO2_ppb, Bruit_dB, Temperature_C, Humidite_pct, Pluie_mm, Vent_mps, NDVI
- Ordinales : Perception_air_1a5 (1 mauvais → 5 bon), Gene_bruit_1a5 (1 faible → 5 forte), Risque_inondation (Faible/Moyen/Élevé)
- Avant/Après : Campagne et Phase_intervention (seulement pour la campagne poussière)

## 2) Travail demandé (pipeline imposé)

### A. Nettoyage & préparation

- Chargement des librairies

```
library(ggplot2)
library(readr)
library(dplyr)
library(tidyverse)
library(readxl)
```

- Chargement de la base de données

```
df = read_excel(file.choose())
str(df)
View(df)
```

❖ Calculer le taux de NA par variable + visualiser (barplot)

- **Pourcentage des Valeurs manqantes**

```
is.na(df)
na_col = colSums(is.na(df))
pourc = colSums(is.na(df)) / nrow(df) * 100
df_na = data.frame(Variable = names(df),
                   Nbr_val_manquantes = na_col,
                   pourcentage = round(pourc, 2))
print(df_na)
```

- **Visualisation(barplot)**

```
barplot(pourc,
        main = "Taux des valeurs manquantes par variable",
                ylab = "Pourcentage des NA",
                col = "blue",
               las = 2 )
```

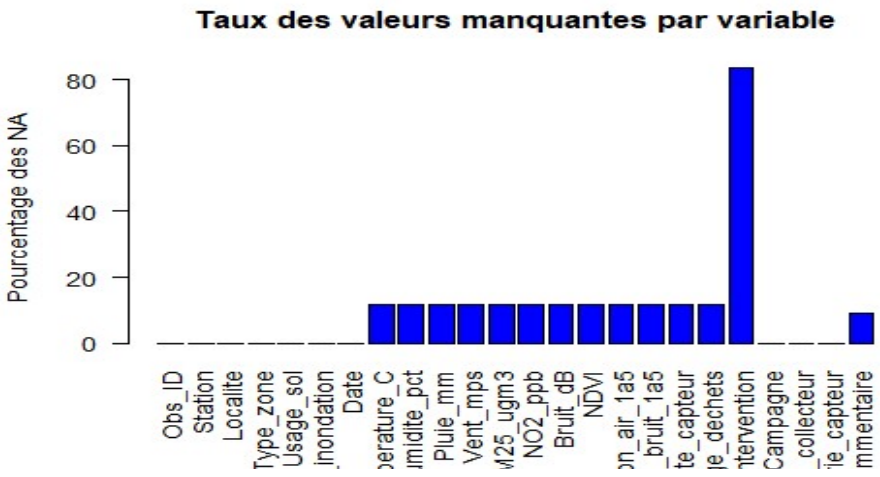


Commentaire : Le graphique montre les variables qui présentent des données manquantes. Presque toutes ces variables on les mêmes

Pourcentages de valeurs manquantes sauf Phase_intervention qui a la plus grande valeur

Ces variables nécessitent un traitement

❖ des NA (imputation simple((médiane/Mode))

**Justification** : Elle garantit la stabilité face aux valeurs extrêmes et la simplicité d'interprétation en préservant l'ensemble des données

La médiane n’est pas influencée par les valeurs extrêmes et conserve une valeur centrale réaliste.

- variables quantitatives à imputer
  vars_quant = c ("PM25_ugm3", "NO2_ppb", "Bruit_dB", "Temperature_C", "Humidite_pct","Pluie_mm", "Vent_mps", "NDVI" )

```
df$PM25_ugm3[is.na(df$PM25_ugm3)] = median(df$PM25_ugm3, na.rm = TRUE)

df$NO2_ppb[is.na(df$NO2_ppb)] = median(df$NO2_ppb, na.rm = TRUE)

df$Bruit_dB[is.na(df$Bruit_dB)] = median(df$Bruit_dB, na.rm = TRUE)

df$Temperature_C[is.na(df$Temperature_C)] = median(df$Temperature_C, na.rm = TRUE)

df$Humidite_pct[is.na(df$Humidite_pct)] = median(df$Humidite_pct, na.rm = TRUE)

df$Pluie_mm[is.na(df$Pluie_mm)] = median(df$Pluie_mm, na.rm = TRUE)

df$Vent_mps[is.na(df$Vent_mps)] = median(df$Vent_mps, na.rm = TRUE)

df$NDVI[is.na(df$NDVI)] = median(df$NDVI, na.rm = TRUE)

colSums(is.na(df))

View(df)
```

- variables qualitatives imputation par mode

Le mode respecte la catégorie la plus représentative et maintient les catégories existantes sans en créer de nouvelle

```
vars_qual = c("Type_zone", "Usage_sol", "Risque_inondation", "Qualite_capteur", "Brulage_dechets", "Localite", "Station", "Perception_air_1a5", "Gene_bruit_1a5", "Risque_inondation")
```

Type_zone, Locatilte, Usage_sol, Station, Risque_inondation n'ont pas de donnees manquant donc pas de traitement

```
mode_brulage <- names(sort(table(df$Brulage_dechets), decreasing = TRUE))

df$Brulage_dechets[is.na(df$Brulage_dechets)] <- mode_brulage



mode_qualite <- names(sort(table(df$Qualite_capteur), decreasing = TRUE))

df$Qualite_capteur[is.na(df$Qualite_capteur)] <- mode_qualite


mode_perception <- names(sort(table(df$Perception_air_1a5), decreasing = TRUE))

df$Perception_air_1a5[is.na(df$Perception_air_1a5)] <- mode_perception


mode_gene <- names(sort(table(df$Gene_bruit_1a5), decreasing = TRUE))

df$Gene_bruit_1a5[is.na(df$Gene_bruit_1a5)] <- mode_gene
```

```
mode_comment <- names(sort(table(df$Commentaire), decreasing = TRUE))
df$Commentaire[is.na(df$Commentaire)] <- mode comment

mode_camp <- names(sort(table(df$Campagne), decreasing = TRUE))
df$Campagne[is.na(df$Campagne)] <- mode_camp

mode_phase <- names(sort(table(df$Phase_intervention), decreasing = TRUE))
df$Phase_intervention[is.na(df$Phase_intervention)] <- mode_phase

colSums(is.na(df))
View(df)
```

- Verification après traitement

```
is.na(df)
na_col = colSums(is.na(df))
pourc = colSums(is.na(df)) / nrow(df) * 100
df_na = data.frame(Variable = names(df),
        Nbr_val_manquantes = na_col,
        pourcentage = round(pourc, 2))
print(df_na)
```

Après le traitement on voit que tous les pourcentages sont nuls

❖ Détection des valeurs aberrantes(boxplot)

- Méthode IQR: interquartile

```
x = df$PM25_ugm3

Q1 = quantile(x, 0.25, na.rm = TRUE)

Q3 = quantile(x, 0.75, na.rm = TRUE)

IQR = Q3 - Q1

borne_inf = Q1 - 1.5 * IQR

borne_sup = Q3 + 1.5 * IQR

outliers = x[x < borne_inf | x > borne_sup]

outliers
```

Résultats : [1] 520.00000 450.00000 86.75493

```
boxplot(df$PM25_ugm3, main = "Traitement des valeurs aberrante pour

PM25_ugm3", col = "orange")
```

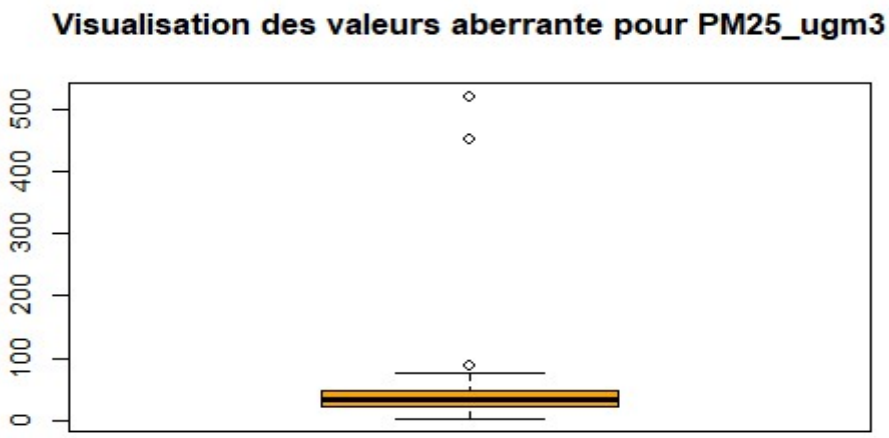


Le boxplot permet de visualiser le nombre de valeurs aberrantes

```
x = df$NO2_ppb

Q1 = quantile(x, 0.25, na.rm = TRUE)

Q3 = quantile(x, 0.75, na.rm = TRUE)

IQR = Q3 - Q1

borne_inf = Q1 - 1.5 * IQR

borne_sup = Q3 + 1.5 * IQR

outliers = x[x < borne_inf | x > borne_sup]

outliers
```

```
Résultat : [1] 180.00000  52.88295
boxplot(df$NO2_ppb, main = "Traitement des valeurs aberrante p
our NO2_ppb", col = "green")
```

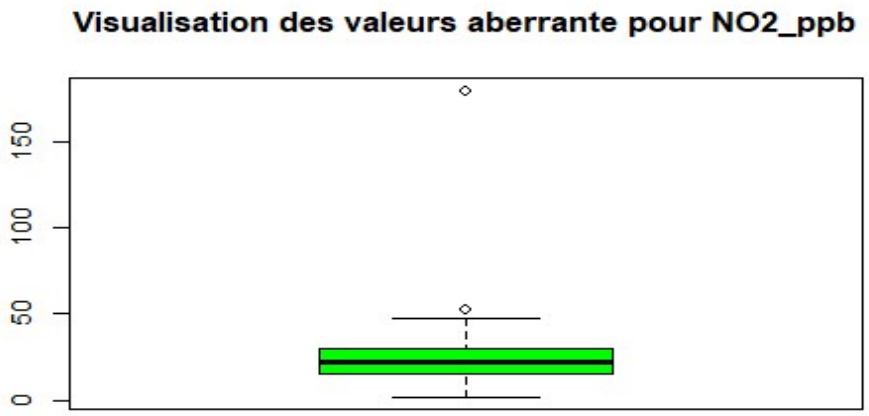


Q1 = quantile(x, 0.25, na.rm = TRUE

Q3 = quantile(x, 0.75, na.rm = TRUE)

IQR = Q3 - Q1

borne_inf = Q1 - 1.5 * IQR

borne_sup = Q3 + 1.5 * IQR

outliers = x[x < borne_inf | x > borne_sup]

outliers

```
Résultat : [1] 110
```

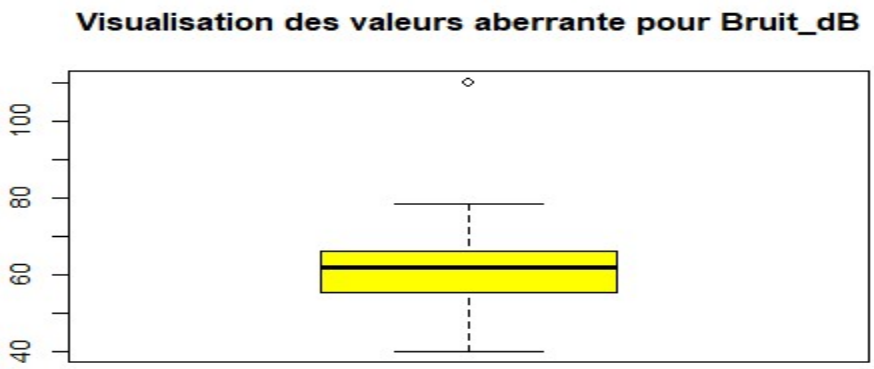

x = df$NDVI

Q1 = quantile(x, 0.25, na.rm = TRUE)

Q3 = quantile(x, 0.75, na.rm = TRUE)

IQR = Q3 - Q1

borne_inf = Q1 - 1.5 * IQR

borne_sup = Q3 + 1.5 * IQR

outliers = x[x < borne_inf | x > borne_sup]

outliers

Résultat : [1]  1.25 -0.25

boxplot(df$NDVI, main = "Traitement des valeurs aberrante pour NDVI", col = "pink")

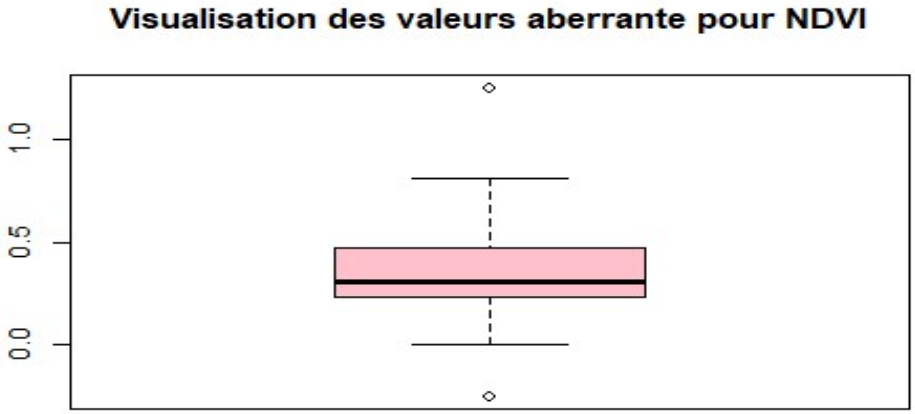


Stratégie proposée : winsorisation, elle garde toutes les données et limite les valeurs extrêmes

x [x < borne_inf] = borne_inf

x [x > borne_sup] = borne_sup

library (DescTools)

df$PM25_ugm3 = Minorize(df$PM25_ugm3)

```
df$NO2_ppb = Winsorize(df$NO2_ppb)

df$Bruit_dB = Winsorize(df$Bruit_dB)

df$NDVI = Winsorize(df$NDVI)
```

## B. Suppression de colonnes (obligatoire)

❖ Suppression de colonnes

```
df$Agent_collecteur = NULL

df$Numero_serie_capteur = NULL

df$Commentaire = NULL

View(df)
```

## C. Ajout de nouvelles colonnes (obligatoire)

1. Saison

```
df$Date = as.Date(df$Date)

mois = as.numeric(format(df$Date, "%m"))

df$Saison = ifelse(mois >=6 & mois <= 10, "Pluie", "Sèche")
```

2. Depassement_PM25

```
df$Depassement_PM25 = ifelse(df$PM25_ugm3 > 55, "Oui",       "Non")
```

3. PM25_log

```
df$PM25_log = log(df$PM25_ugm3)
```

4. Indice_confort

```
df$Indice_confort = df$Temperature_C + 0.1 * df$Humidite_pct

View(df)
```

## D. Visualisations (obligatoires)

❖ Histogramme

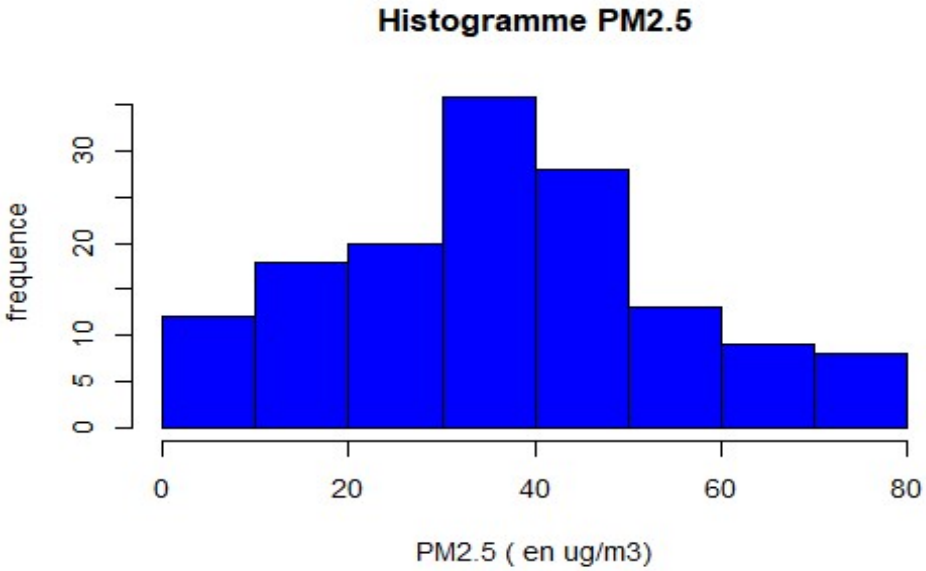


L'histogramme montre que la plupart des concentrations de PM2.5 sont faibles

La distribution est asymétrique à droite, ce qui indique la présence de quelques pics de pollution plus élevé

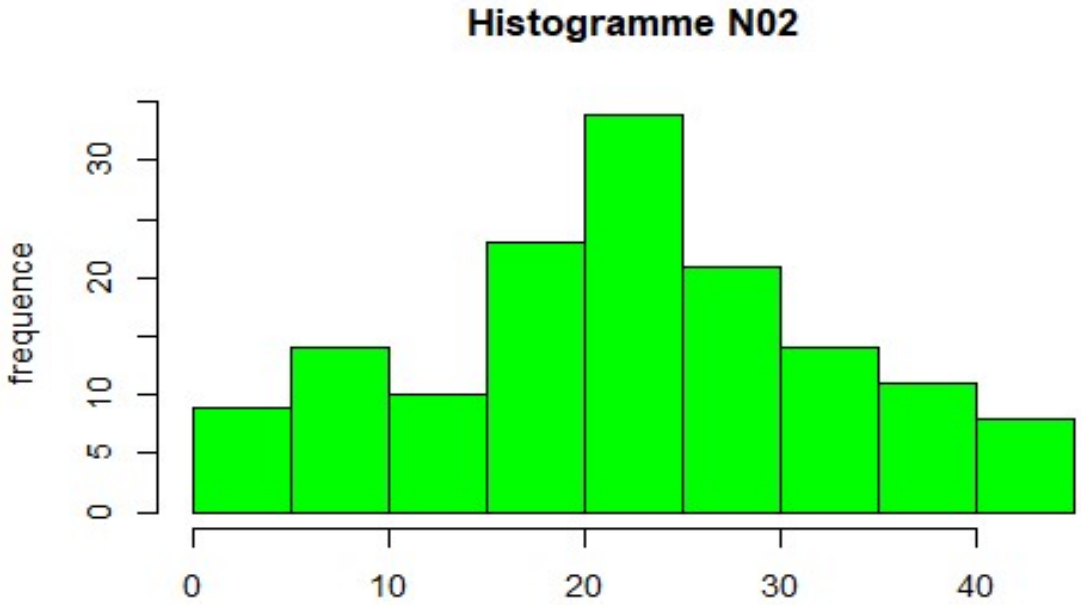

La concentration de $NO_2$ est généralement basse, avec quelques pics élevés

Cela signifie que l'air est souvent bon, mais parfois il y'a de la pollution

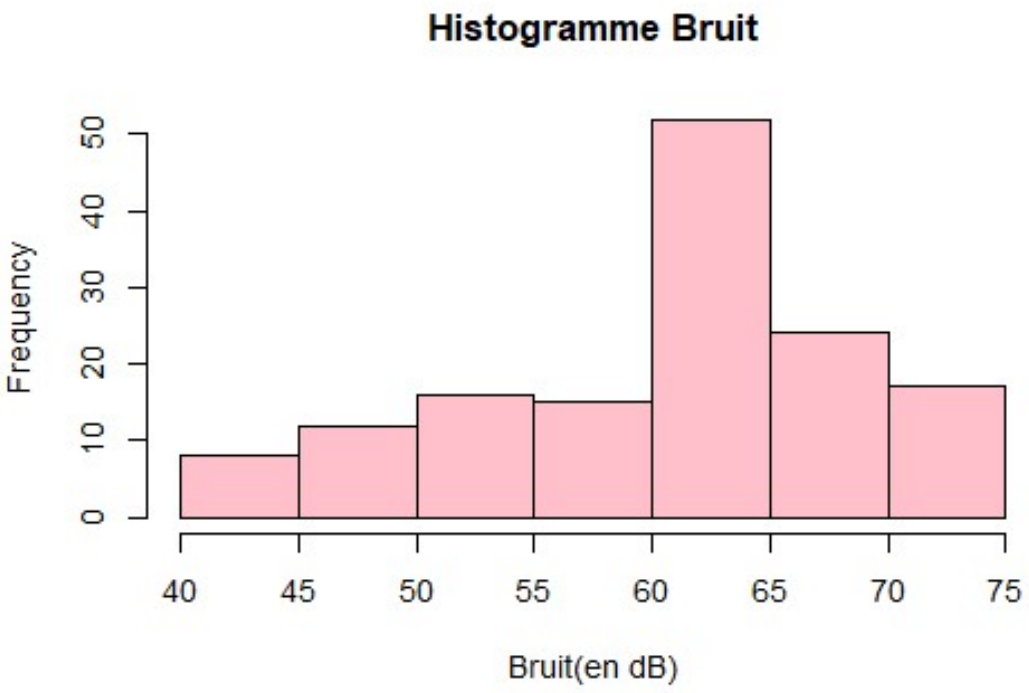


Ce histogramme présente la distribution des mesures de bruit (en dB)

La plupart des niveaux de bruit se situent entre 40 et 60 dB, mais les valeurs extrêmes (à gauche et à droite de l'histogramme) sont peu fréquentes. La classe 60-65 dB montre une proportion importante de bruits

❖ Boxpolots

boxplot(df$PM25_ugm3, main = "Boxplot de PM2.5", col = "blue")

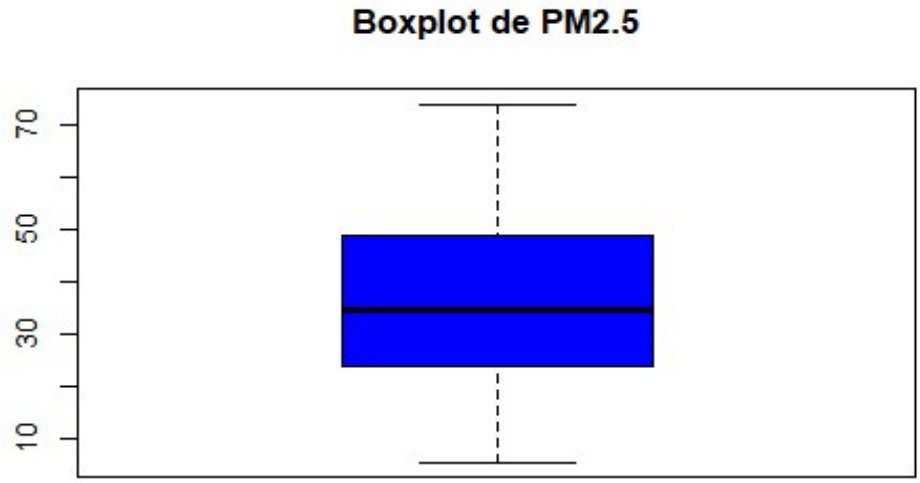


Ce boxplot présente la distribution des concentrations de PM2.5.

On observe une boîte allongée, ce qui indique une dispersion importante des données. La médiane des PM2.5 est très élevée (≈ 34 µg/m³). La dispersion est importante (quartiles ≈ 20 et 42 µg/m³) et de nombreux pics dépassent 50 µg/m³

boxplot(df$NO2_ppb, main = "Boxplot de NO2", col = "green")

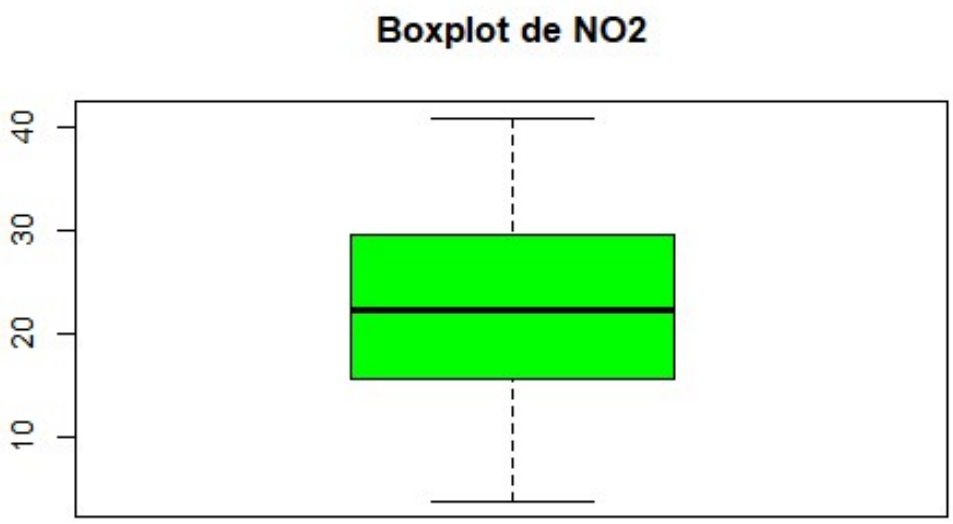

Ce boxplot présente la distribution des concentrations de NO2

Les 50 % des données centrales (boîte) s'étendent d'environ 15 à 30 ppb, montrant une variabilité significative mais sans valeurs extrêmes .

Le $NO_2$ présente une médiane élevée (≈ 25 ppb). La dispersion est modérée (quartiles ≈ 17 et 32 ppb) et l'absence de valeurs extrêmes marquées indique une pollution régulière

Le NO2 présente une pollution de fond constante et généralisée

```
boxplot(df$Bruit_dB, main = "Boxplot de Bruit", col = "pink")
```

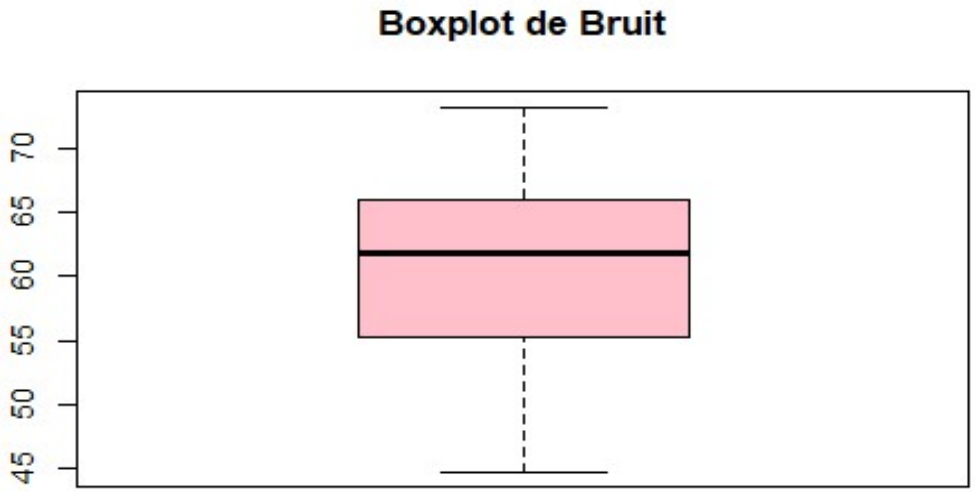


Ce boxplot présente la distribution des concentrations de Bruit

Médiane est environ 62 dB

Premier quartile (Q1) ≈ 57 dB → 25 % des mesures sont inférieures à ce niveau.

Troisième quartile (Q3) ≈ 66 dB → 75 % des mesures sont inférieures à ce

niveau. L’intervalle interquartile (IQR = Q3 – Q1) est d'environ 9 dB, ce qui montre une variabilité modérée mais une concentration des mesures dans l’‘intervalle élevée (57–66 dB).

## ❖ Boxplot de PM25_ugm3 par Type_zone et par Usage_sol

- par Type_zone

```
boxplot(PM25_ugm3 ~ Type_zone, data = df,
    main = "Boxplot PM2.5 par Type_zone",
    xlab = "Type_zone",
    ylab = "PM2.5 ( en ug/m3)",
    col = c("pink", "green", "blue"))
```

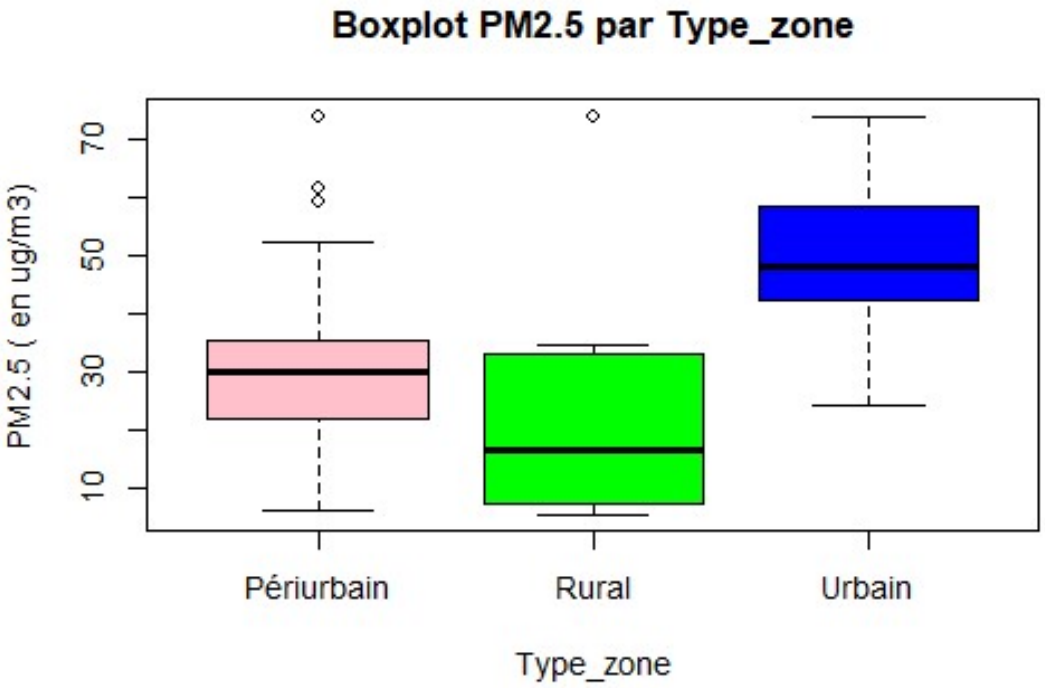

Le boxplot montre que la concentration de PM2.5 est la plus faible en zone rurale, moyenne en zone périurbaine et la plus élevée en zone urbaine

La pollution aux PM2.5 augmente significativement avec l'urbanisation :

Les zones urbaines ont une médiane plus du double de celle des zones rurales, avec une variabilité et des pics bien plus marqués.
Les zones périurbaines subissent une pollution intermédiaire mais non négligeable. La présence et l'intensité des valeurs aberrantes augmentent avec le degré d'urbanisation
Les zones rurales restent exposées à un niveau de fond significatif (médiane > 15 µg/m³)

- par Usage_sol

```
boxplot(PM25_ugm3 ~ Usage_sol, data = df,
    main = "Boxplot PM2.5 par Usage_sol",
    xlab = "Usage_sol",
    ylab = "PM2.5 ( en ug/m3)",
    col = c("red", "yellow", "orange", "blue"))
```

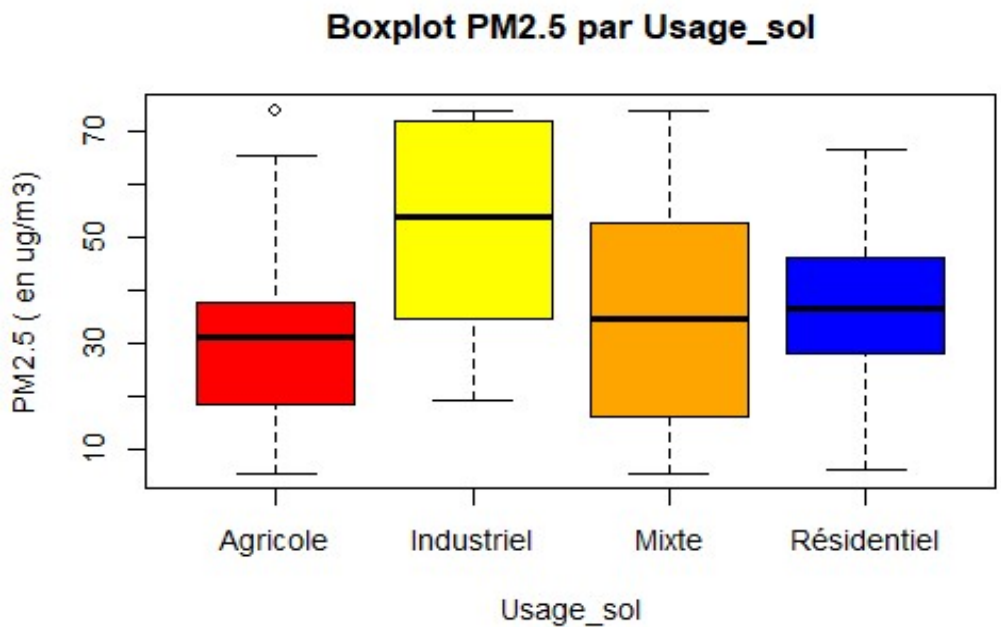

Les concentrations de PM2.5 sont les plus élevées en zone industrielle, ce qui s'explique par les

#émissions liées aux activités industrielles.Les zones mixtes et résidentielles présentent des niveaux intermédiaires de pollution, tandis que les zones agricoles ont les plus faibles concentrations de PM2.5

**Zones industrielles** présentent la pollution la plus intense (médiane ≈ **30** µg/m³) Distribution étendue avec plusieurs valeurs au-delà de 50 µg/m³.

**Zones résidentielles** ont une médiane élevée et Quelques valeurs au-delà de 40 µg/m³.

**Zones mixtes** affichent une pollution notable (médiane ≈ 29 µg/m³) et quelques pics, résultat combiné de diverses sources d'émission.

**Zones agricoles**, bien que moins touchées  avec une médiane plus faible

- ❖ Scatter PM25_ugm3 vs NO2_ppb (avec tendance)

```
ggplot(df, aes(x = PM25_ugm3, y = NO2_ppb)) +
  geom_point(color = "blue") +
  geom_smooth(method = "lm", col = "red", se = FALSE)
  labs(title = "Relation entre PM2.5 et NO2",
      x = "PM2.5(en ugm3)", y = "NO2(en ppb)",) +
  theme_minimal()
```

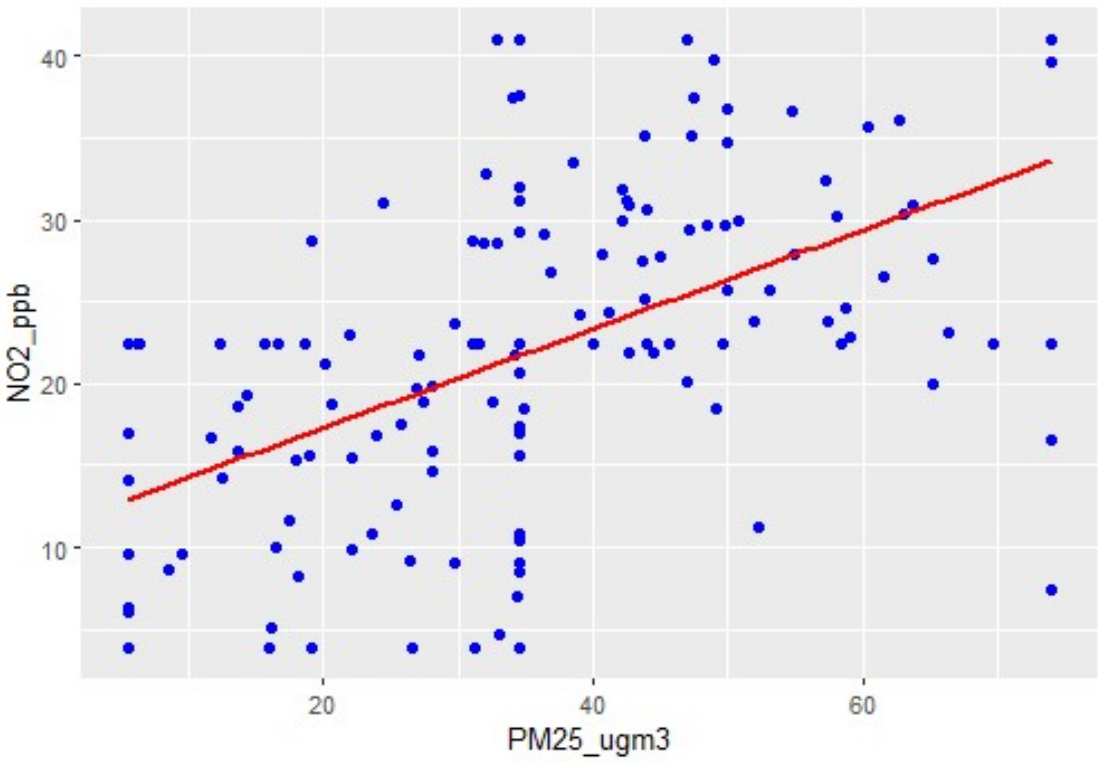


La concentration de PM2.5 et de NO2 augmente ensemble. La ligne rouge montre une tendance positive, ce qui signifie que ces deux polluants sont liés.

Les points dispersés indiquent que la relation n'est pas parfaite, mais il existe une realtion positive

## ❖ Scatter PM25_ugm3 vs NDVI

```
ggplot(df, aes(x = PM25_ugm3, y = NDVI)) +
  geom_point(color = "green") +
  labs(title = "Relation entre PM2.5 et NDVI",
       x = "PM2.5(en ugm3)", y = "NDVI") +
  theme_minimal()
```

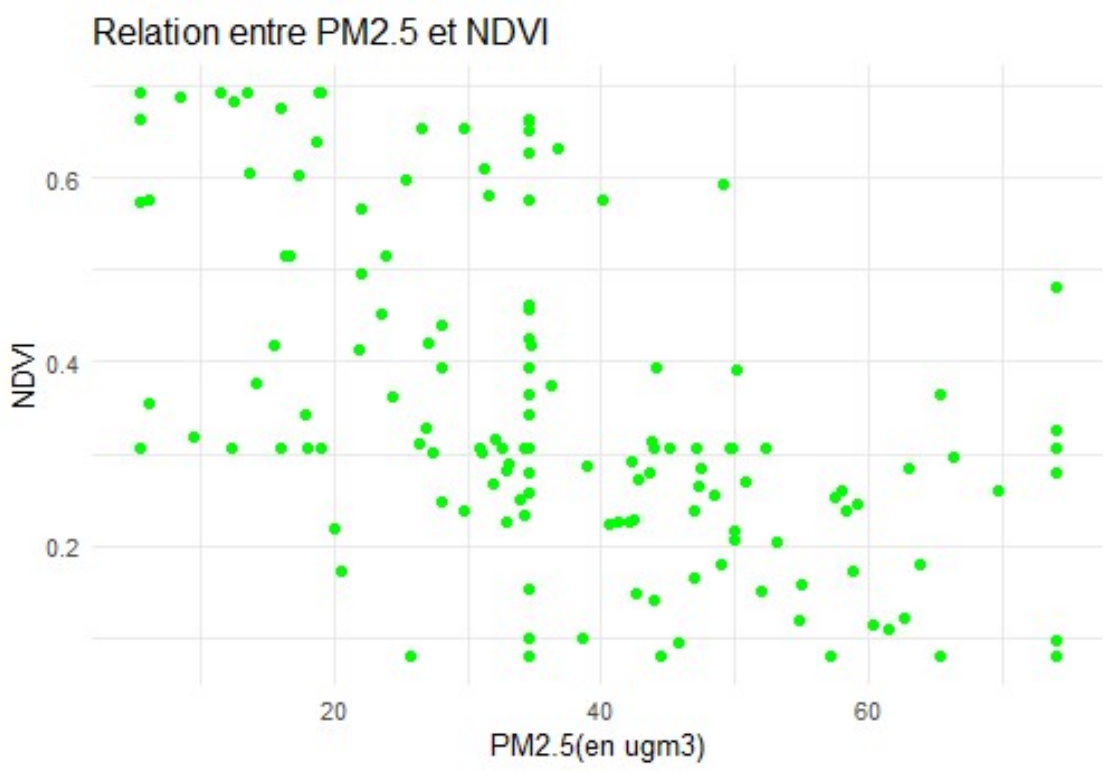


Plus le NDVI (végétation) est élevé, plus les PM2.5 ont tendance à être bas.

Les zones faiblement végétalisées (NDVI < 0.2) montrent les PM2.5 les plus élevés (> 30 µg/m³), tandis que les zones ou la NDVI > 0.4 présentent généralement des concentrations plus faibles (< 25 µg/m³).

Il existe une tendance générale à la baisse des PM2.5 avec l'augmentation du NDVI, mais avec une dispersion significative.

- ❖ Série temporelle : PM2.5 par mois (moyenne globale ou par zone)
  - Moyenne globale

```
mois <- as.numeric(format(df$Date, "%m"))

pm25_moy <- tapply(df$PM25_ugm3, mois, mean, na.rm = TRUE)
```

```
plot(pm25_moy, type = "b",
    main = "Série temporelle : PM2.5 par mois(moyenne globale)",
    xlab = "Mois",
    ylab = "PM2.5 (µg/m³)")
```

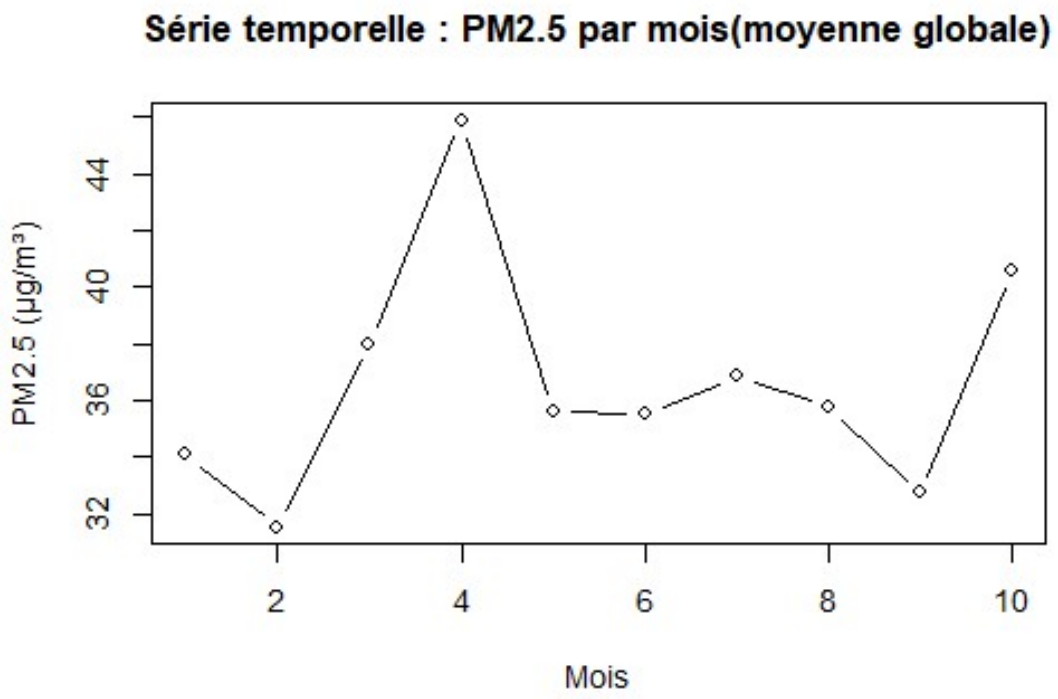


Le graphique montre l'évolution des concentrations moyennes de PM2.5 par mois. Un pic de concentration est observé au mois 4. Les valeurs se stabilisent entre les mois 5 et 8, puis baissent au mois 9.

Le mois 10 montre une remontée des concentrations.

❖ Heatmap/corrélogramme (sur quanti)

```
library(ggcorrplot)

quanti_sel <- df %>% select(PM25_ugm3, NO2_ppb, Bruit_dB, Temperature_C,
PM25_log,Indice_confort,
                            Humidite_pct, NDVI, Indice_confort,Pluie_mm, Vent_mps)

mat_cor <- cor(quanti_sel, use = "complete.obs")

ggcorrplot(mat_cor, method = "square",lab = TRUE, type = "upper")
```

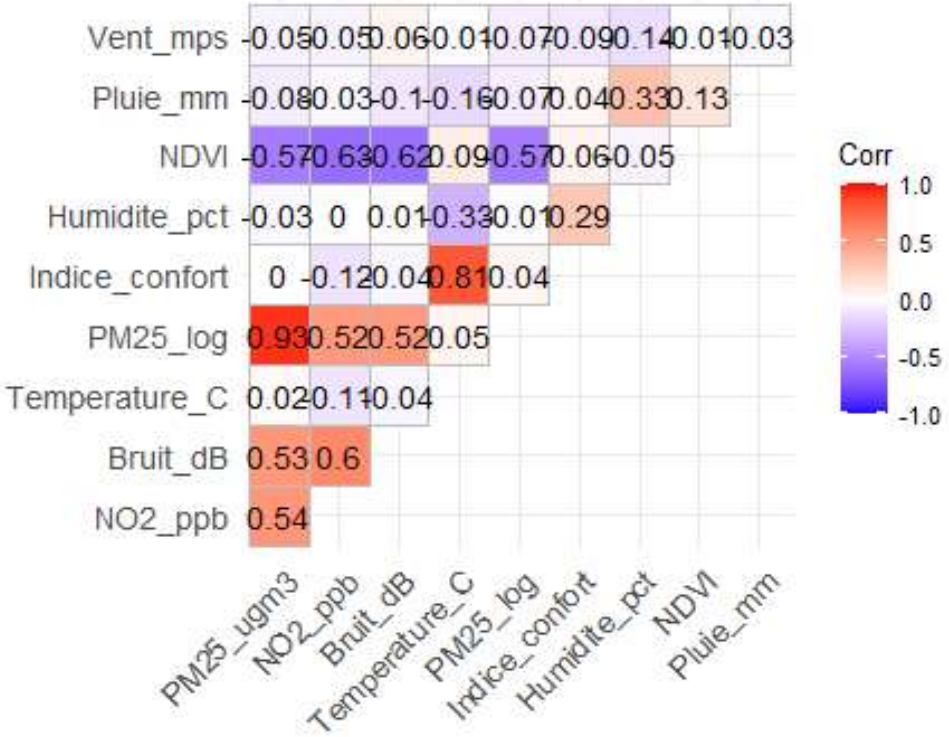


La matrice de corrélation révèle plusieurs relations clés. La végétation (NDVI) est fortement négativement corrélée avec les PM2.5 (-0.57), confirmant son rôle modérateur sur la pollution. Une forte relation positive existe entre les indicateurs de trafic et d'activité urbaine : le bruit, le $NO_2$ et les PM2.5 sont liés (corrélations entre 0.52 et 0.6). L'indice de confort dépend principalement de la température (corrélation de 0.81). En revanche, les variables météorologiques

comme le vent montrent des corrélations très faibles avec la pollution.

L'humidité et le NDVI ont une faible corrélation négative (-0.03)

## 3) Questions statistiques

### 1) Quali × Quali : Chi-deux / Fisher + V de Cramer

Le dépassement PM2.5 dépend-il du type de zone ?

- Analyse univariée
  - dépassement PM2.5

table(df$Depassement_PM25)

```
Non Oui
121  23
```

pour le depassement on a 23 Oui et 121 Non

  - Type de zone

table(df$Type_zone)

```
Périurbain      Rural     Urbain
        48         36         60
```

Pour les Types de zone on a: 48 zone Périurbains, 36 zones Rurales et 60 zones Urbains

- Analyse bivariée

Tableau de contingence

tab <- table(df$Depassement_PM25, df$Type_zone)

tab

```
Périurbain Rural Urbain
  Non         45    35     41
  Oui          3     1     19
```

on a pour les zones Périurbains: 45 qui n'ont pas de Depassement_PM25 et 3 qui ont de Depassement_PM25

Pour les zones Rurales : 35 qui n'ont pas de Depassement_PM25 et 1 qui a de Depassement_PM25

pour les zones Urbains :41 qui n'ont pas de Depassement_PM25 et 19 qui ont un Depassement_PM25

- Répartition des type de zone selon le depassement

```
ggplot(df, aes(x = Depassement_PM25, fill = Type_zone)) +
  geom_bar(position = "fill") +
  labs(title = "Répartition des type de zone selon le depassement",
       x = "Depassement PM2.5", y = "Proportion") +
  theme_minimal()
```

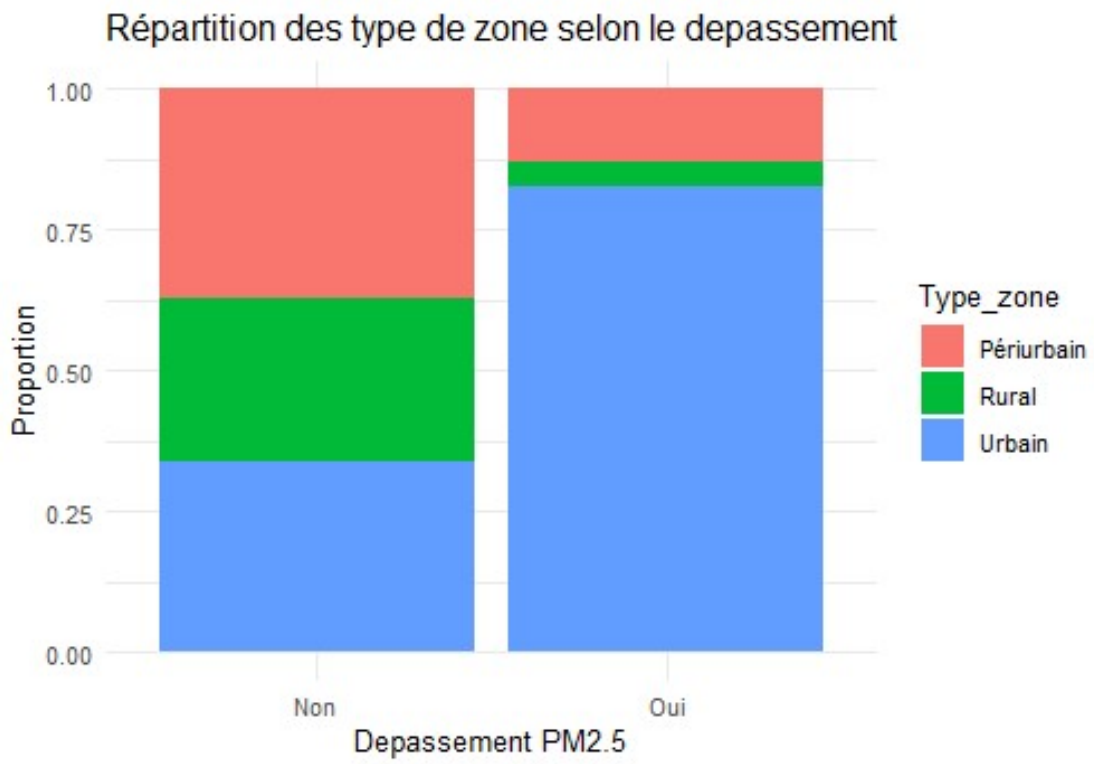

Commentaire : le graphe montre qu'on a un proportion importante de zones urbains qui ont un dépassement

suivi des zones périurbains et enfin les zones rural avec une faible proportion

On voit aussi que les zones périurbaines non depassement ont une proportion supérieure suivi des zones rurales et urbains qui ont presque la même proportion. Le dépassement de PM2.5 dépend fortement du type de zone : Il est plus fréquent en zone urbaine, Moins fréquent en zone rurale, Et intermédiaire en zone périurbaine.

- Test du Chi-deux

Conditions : Les variables sont catégorielles et indépendantes et d'apres le tableau de contingence les cellules qui ont au moins 5 observations

sont supérieures donc on peut appliquer le Test du Chi-deux

**H0**: Il y'a pas de lien entre dépassement_PM25 et type de zone

**H1**: Il y'a un lien entre dépassement_PM25 et type de zone

Test du Chi-deux d'indépendance

chi <- chisq.test(tab)

chi

```
Résultats: Pearson's Chi-squared test

data:  tab
X-squared = 19.062, df = 2, p-value = 7.257e-05
```

D'après le test la p_value est inférieure à 0.05 ,le résultat est statiquement signi ficatif donc il y'a un lien entre le dépassement_PM25 et le type de zone

- Mesure d'intensité : V de Cramer

library(vcd)

assocstats(tab)

```
Résultat : Phi-Coefficient: NA
Contingency Coeff : 0.342
Cramer's V: 0.364
```

D'apres le V de Cramer, il y'a une forte relation entre le dépassement_PM25 et le type de zone

**Conclusion générale**: Le dépassement PM2.5 dépend du type de zone

**2) Quali × Quali : association "terrain"**

Le brûlage de déchets dépend-il de la zone (urbain/périurbain/rural) ?

- ✓ Brulage

table(df$Brulage_dechets)

```
Non Oui
109  35
```

pour le Brulage, on a 35 Oui et 109 Non

- ✓ Type de zone

table(df$Type_zone)

```
Périurbain      Rural     Urbain
        48         36         60
```

Pour les Types de zone on a: 48 zone Périurbains, 36 zones Rurales et 60 zones Urbains

- ❖ Analyse bivariée

Tableau de contingence

tab <- table(df$Brulage_dechets, df$Type_zone)

tab

```
      Périurbain Rural Urbain
  Non         39    26     44
  Oui          9    10     16
```

On a pour les zones Périurbains: 39 qui n'ont pas de Brulage de dechets et 9 qui ont de Brulage de dechets

Pour les zones Rurales : 26 qui n'ont pas de Brulage de déchets et 10 qui ont d e Brulage de dechets

Pour les zones Urbains :44 qui n'ont pas de Brulage de dechets et 16 qui ont de Brulage de déchets

- Répartition des type de zone selon le depassement

```
ggplot(df, aes(x = Brulage_dechets, fill = Type_zone)) +
  geom_bar(position = "fill") +
  labs(title = "Répartition des type de zone selon le Brulage de déchets",
       x = "Brulage de déchets", y = "Proportion") +
  theme_minimal()
```

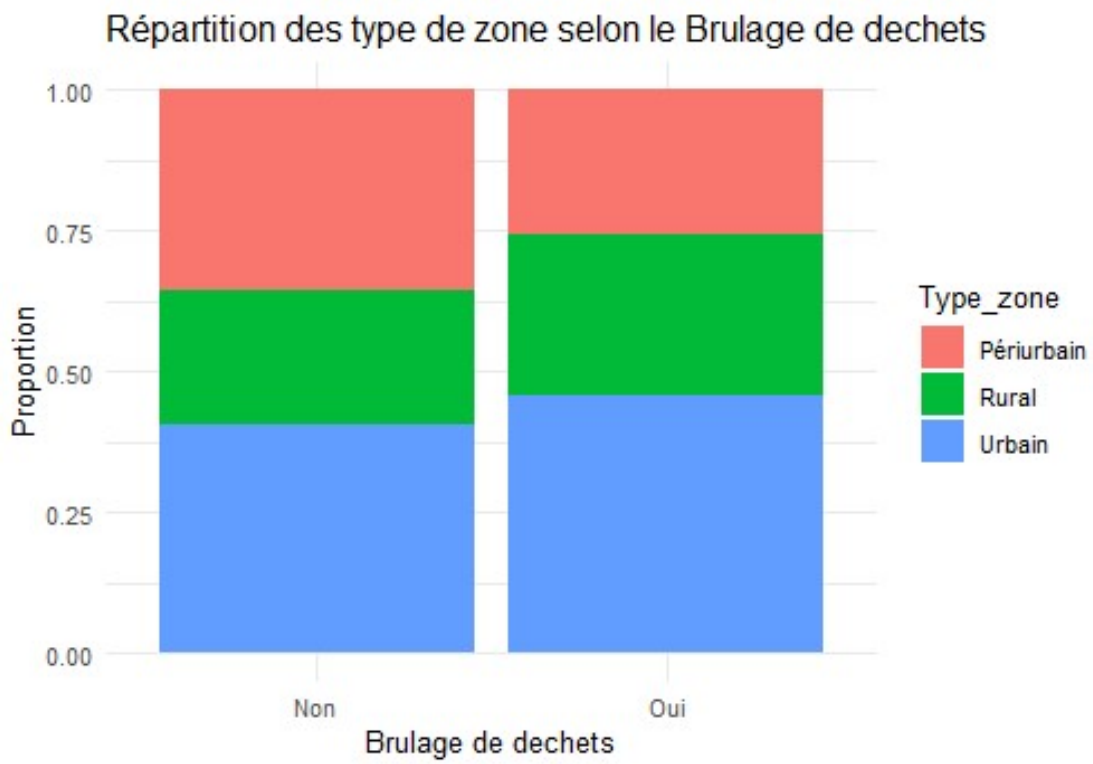


Commentaire: le graphe montre que la proportion de zone urbain avec brûlage de déchets est supérieure à celle de rural et périurbain avec brulage de déchets

On voit aussi que pour les zones non brûlages de déchets, la zone rurale a une proportion petit par contre la proportion pour les zones urbain est supérieure à celle de périurbain. Le graphique révèle que la pratique du brûlage des déchets est plus répandue en zone urbaine qu'en zone rurale.

La zone périurbaine se situe à un niveau intermédiaire

- ❖ Test du Chi-deux

Conditions : Les variables sont indépendantes et catégorielles et d'après le tableau de contingence les cellules qui ont au moins 5 observations sont supérieurs donc on peut appliquer le Test du Chi-deux

**H0**: Il y'a pas de lien entre type de zone et Brulage de déchets

**H1**: Il y'a un lien entre type de zone et Brulage de déchets

Test du Chi-deux d'indépendance

chi <- chisq.test(tab)

chi

```
Résultats: Pearson's Chi-squared test
data:  tab
X-squared = 1.223, df = 2, p-value = 0.5425
```

D'après le test la p_value est supérieure à 0.05 ,le résultat montre qu'il n y'a pa s de lien entre le type de zone et le Brulage de déchets

**conclusion générale** :Le brûlage de déchets ne dépend pas de la zone(urbain/p ériurbain/rural)

## 3) Quanti × Quanti : Pearson vs Spearman

PM2.5 est-il corrélé au $NO_2$ ?

- ➢ Description univariée
  - Pour le PM2.5

**summary(df$PM25_ugm3)**

Min. 1st Qu.  Median  Mean 3rd Qu.  Max.

5.466  23.777  34.597  36.506  48.560  74.063

Commentaire : le PM25_ugm3 indique

un minimum de 5.466ug/m3 , un maximum de 74,063 et une moyenne de 37.5 06ug/m3

25% des valeurs sont inférieures ou égales à 23.777, 50% des valeurs sont inféri eures ou égales à 34.597 et

75% des valeurs sont inférieures ou égales à 48.560

**boxplot(df$PM25_ugm3**)

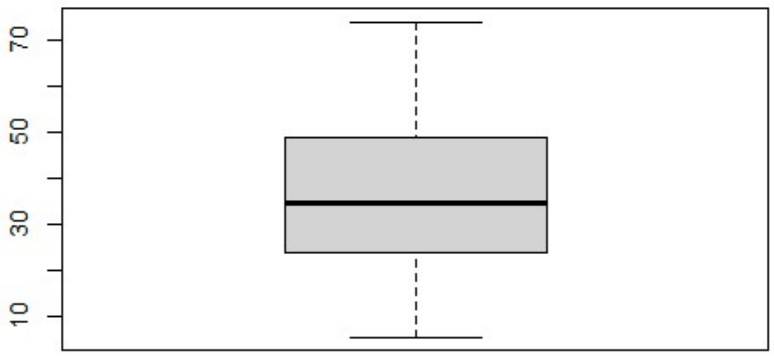


minimum (min) : ≈ 5 c’est La plus petite valeur observée dans les données.

Premier quartile (Q1) : 25 % des valeurs sont inférieures ou égales à 23.

Médiane : 50 % des valeurs sont inférieures ou égales à 33 et 50 % supérieures.

Troisième quartile (Q3) : 75 % des valeurs sont inférieures ou égales à 47.

Maximum (max) : ≈ 74 C'est la plus grande valeur observée.

- Pour le NO2

**summary(df$NO2_ppb)**

Min. 1st Qu. Median Mean 3rd Qu. Max.

3.835 15.595 22.393 22.272 29.604 41.037

Commentaire : le NO2_ppb indique

un minimum de 3.835 ppb , un maximum de 41.037 et une moyenne de 22.272

25% des valeurs sont inférieures ou égales à 15.595, 50% des valeurs sont inféri

eures ou égales à 22.393 et 75% des valeurs sont inférieures ou égales à 29.604

**boxplot(df$NO2_ppb)**

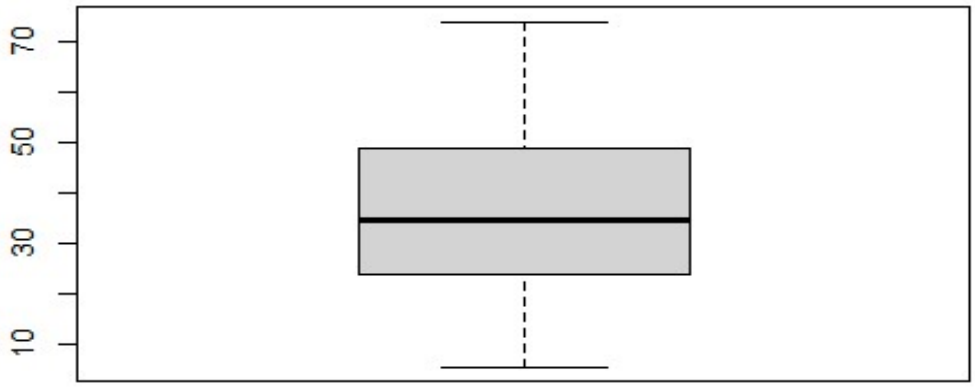


Minimum (min) **:** ≈ 4 Plus petite valeur observée.

Premier quartile (Q1) **:** 25 % des valeurs sont ≤ 16**.**

Médiane (Q2) **:** 50 % des valeurs sont ≤ 22 et 50 % sont ≥ 22**.**

Troisième quartile (Q3) **:** 75 % des valeurs sont ≤ 30**.**

Maximum (max) **:** ≈ 41 Plus grande valeur observée

- Description bivariée

Nuage de points entre les 2 variables

```
plot(df$PM25_ugm3, df$NO2_ppb,
    main = "Relation entre PM2.5 et NO2",
    xlab = "PM2.5 (ugm3)", ylab = " NO2(ppb)")
```

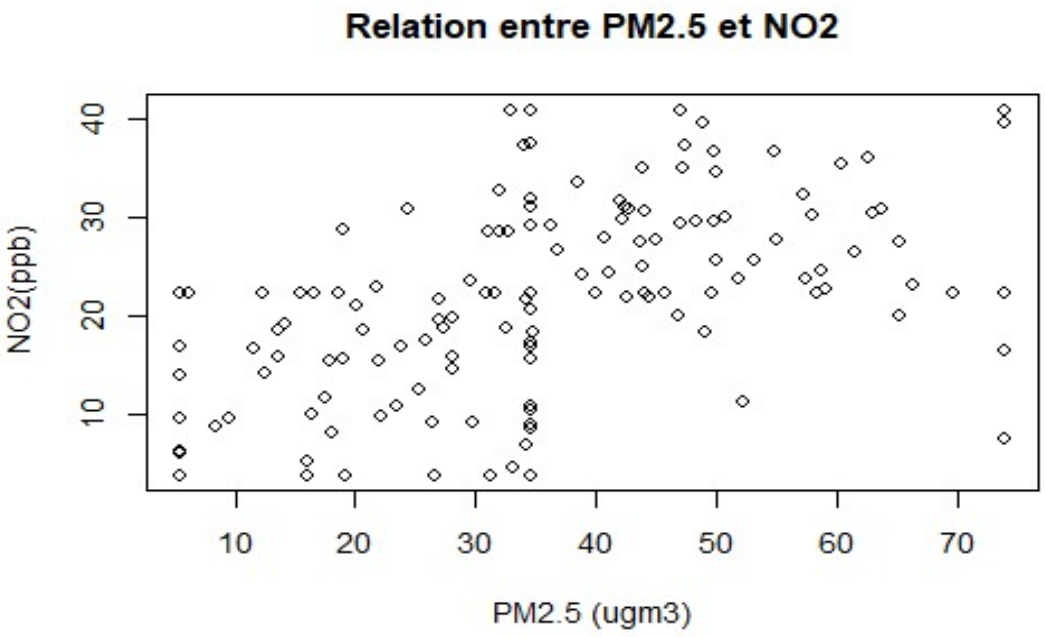


lorsque les concentrations de **PM2.5** augmentent, les niveaux de **$NO_2$** ont tendance à augmenter également.

Le nuage de points ne suit pas une droite : les points sont largement dispersés

- Vérification de la linéarité et de la normalité

Pour la linéarité (voir Description bivariée)

IL n y'a pas linéarité d'apres la Description bivariée

Pour la normalité test de **Shapiro**

**H0**:p_value < = 0.05: normalité rejetée

**H1**: p_value > 0.05: normalité plausible

shapiro.test(df$PM25_ugm3)

shapiro.test(df$NO2_ppb)

```
shapiro.test(df$PM25_ugm3)

	Shapiro-Wilk normality test

data:  df$PM25_ugm3
W = 0.97101, p-value = 0.003776

> shapiro.test(df$NO2_ppb)

	Shapiro-Wilk normality test

data:  df$NO2_ppb
W = 0.97065, p-value = 0.003471
```

Commentaire : D'Apres le test de Shapiro la normalité est rejeté car la p_value est inférieur à 0.05

- Test de corrélation

On fait la corrélation de **Spearman**

Conditions : pas besoin de normalité et

les variables peuvent être linéaires ou non

INTERPRETATION

Valeur proche de -1: Forte corrélation négative monotone

Valeur proche de 0: Aucune relation monotone évidente

Valeur proche de 1: Forte corrélation positive monotone

cor.test(df$PM25_ugm3, df$NO2_ppb, method="spearman")

```
     Spearman's rank correlation rho

data:  df$PM25_ugm3 and df$NO2_ppb
S = 212526, p-value = 6.203e-14
alternative hypothesis: true rho is not equal to 0
sample estimates:
      rho
0.5729331
```

D'apres la corrélation de Spearman on a une forte corrélation positive monotone entre le PM2.5 et le NO2

**Conclusion générale** : Le PM2.5 est corrélé au NO2

## 4) Quanti × Quanti

La végétation (NDVI) est-elle associée à la pollution (PM2.5) ?

- Description univariée
  - Pour NDVI

**summary(df$NDVI)**

un minimum de 0.07934 , un maximum de 0.69263 et une moyenne de 0.35257

25% des valeurs sont inférieures ou égales à 0.23602, 50% des valeurs sont inférieures ou égales à 0.30505 et

75% des valeurs sont inférieures ou égales à 0.46669

**boxplot(df$NDVI)**

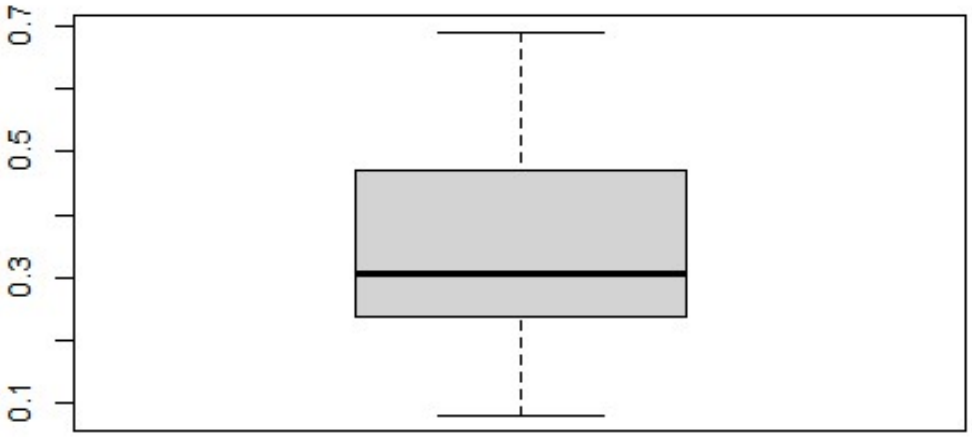


Minimum (min) : ≈ 0,15 Plus petite valeur observée.

Premier quartile (Q1) : 25 % des valeurs sont ≤ 0,25.

Médiane (Q2) : 50 % des valeurs sont ≤ 0,3 et 50 % sont ≥ 0,3.

Troisième quartile (Q3) : 75 % des valeurs sont ≤ 0,35.

Maximum (max) : 0,68 Plus grande valeur observée.

**summary(df$PM25_ugm3)**

Min. 1st Qu.  Median  Mean 3rd Qu.  Max.

5.466  23.777  34.597  36.506  48.560  74.063

Commentaire : le PM25_ugm3 indique

un minimum de 5.466ug/m3 , un maximum de 74,063 et une moyenne de 37.5 06ug/m3

25% des valeurs sont inférieures ou égales à 23.777, 50% des valeurs sont inféri eures ou égales à 34.597 et

75% des valeurs sont inférieures ou égales à 48.560

**boxplot(df$PM25_ugm3)**

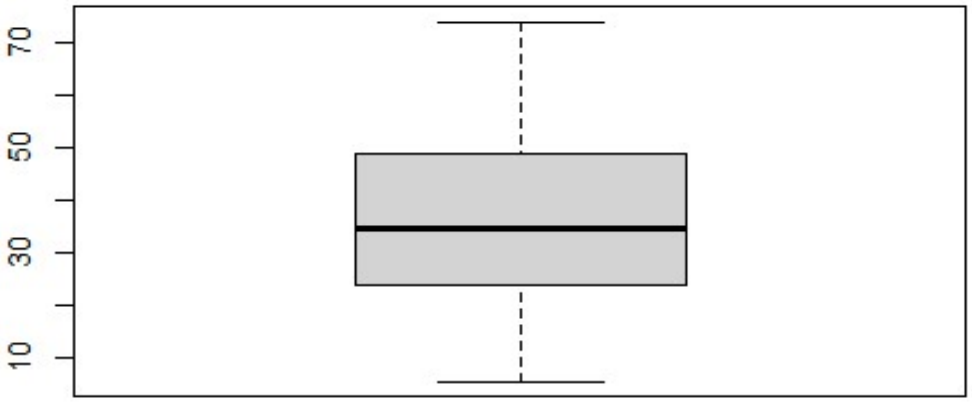


Commentaire :

minimum (min) : ≈ 5 c'est La plus petite valeur observée dans les données.

Premier quartile (Q1) : 25 % des valeurs sont inférieures ou égales à 23.

Médiane : 50 % des valeurs sont inférieures ou égales à 33 et 50 % supérieures.

Troisième quartile (Q3) : 75 % des valeurs sont inférieures ou égales à 47.

Maximum (max) : ≈ 74 C'est la plus grande valeur observée

## ➢ Description bivariée

- Nuage de points entre les 2 variables

```
plot(df$NDVI, df$PM25_ugm3,
    main = "Relation entre NDVI et PM2.5",
    xlab = "NDVI", ylab = " PM2.5(ug/m3)")
```

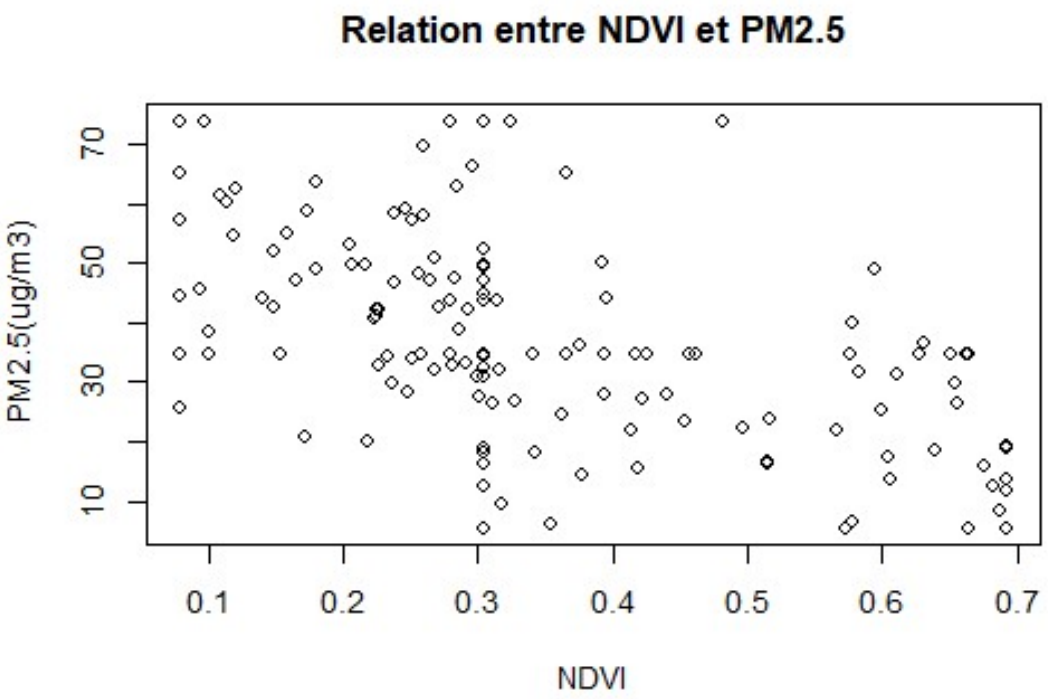


Le nuage de points ne suit pas une droite : les points sont largement dispersés

Cela montre que la relation entre le NDVI et le PM2.5 n'est pas linéaire

Plus NDVI est élevé, plus PM2.5 est faible

- Vérification de la linéarité et de la normalité

Pour la linéarité (voir Description bivariée)

IL n y'a pas linearite d'apres la Description bivariée

Pour la normalité test de **Shapiro**

**H0**:p_value < = 0.05: normalité rejetée

**H1**: p_value > 0.05: normalité plausible

shapiro.test(df$NDVI)

shapiro.test(df$PM25_ugm3)

```
shapiro.test(df$NDVI)

        Shapiro-Wilk normality test

data:  df$NDVI
W = 0.92181, p-value = 4.419e-07

> shapiro.test(df$PM25_ugm3)

        Shapiro-Wilk normality test

data:  df$PM25_ugm3
W = 0.97101, p-value = 0.003776
```

La p_value est inférieur à 0.05 Donc la normalité est rejetée

- Test de corrélation

Corrélation de **Spearman**

Conditions:

Pas besoin de normalité et les variables peuvent être linéaires ou non

INTERPRETATION

Valeur proche de -1: Forte corrélation négative monotone

Valeur proche de 0: Aucune relation monotone évidente

Valeur proche de 1: Forte corrélation positive monotone

cor.test(df$NDVI, df$PM25_ugm3, method="spearman")

```
        Spearman's rank correlation rho

data:  df$NDVI and df$PM25_ugm3
S = 790638, p-value = 8.407e-15
alternative hypothesis: true rho is not equal to 0
sample estimates:
```

```
rho       -0.5887749
```

D'apres la correlation de Spearman on a une forte corrélation négative monoto ne

Plus l'indice de végétation (NDVI) est élevé, plus la concentration en PM2.5 ten d à être faible

**Conclusion générale**: La végétation (NDVI) est associée négativement à la pollu tion (PM2.5)

**5) Quanti × Quali (2 groupes): Student / Welch / Mann–Whitney**

Le PM2.5 est-il différent quand il y a brûlage (Oui/Non) ?

```
df$Brulage_dechets <- as.factor(df$Brulage_dechets)
```

- ✓ Description univariées des variables

Pour la variable qualitative 'Brulage_dechets'

```
brulage_dechets_table <- table(df$Brulage_dechets)
brulage_dechets_table
```

Commentaire : pour le Brulage, on a 35 Oui et 109 Non

Répartition par brulage de dechets

```
barplot(brulage_dechets_table,
        main = "Distribution des brulage",
        xlab = "Brulage de dechets",
        ylab = "Fréquence")
```

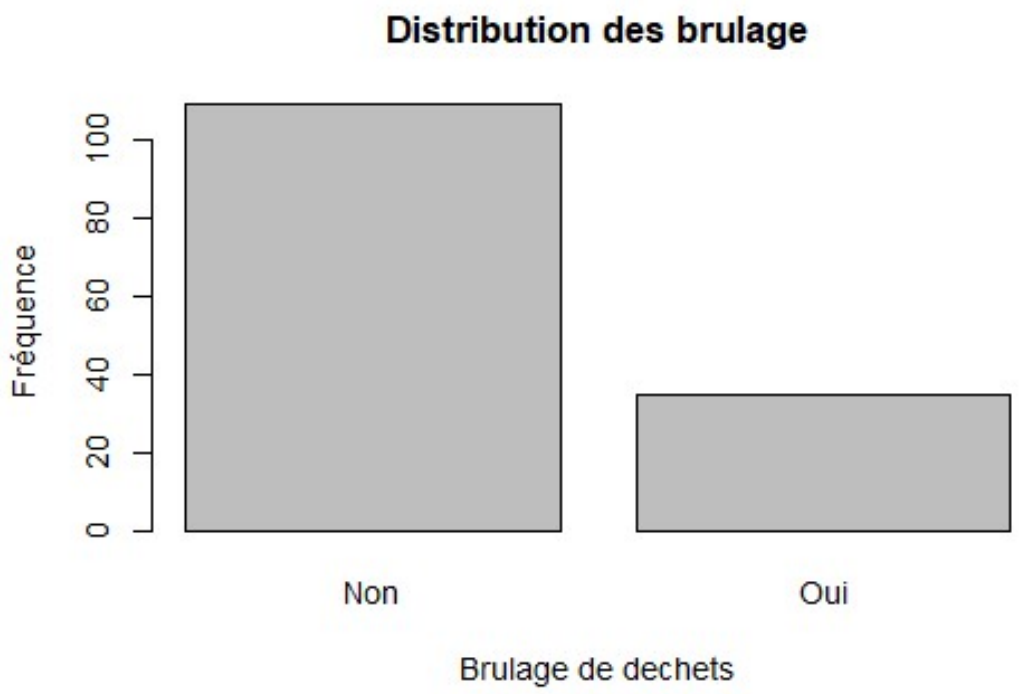


Commentaire : La barre avec non brulage est plus haut par rapport à la barre avec brulage .  Donc le brulage est minoritaire

- ✓ Distribution de la variable quantitative 'PM25_ugm3'

**summary(df$PM25_ugm3)**

Commentaire:

le PM25_ugm3 indique:

un minimum de 5.466ug/m3 , un maximum de 74,03 et une moyenne de 36.506ug/m3

25% des valeurs sont inférieures ou égales à 23.777, 50% des valeurs sont inférieures ou égales à 34.597 et

75% des valeurs sont inférieures ou égales à 48.560

**Histogramme des PM2.5**

ggplot(df, aes(x = PM25_ugm3)) +

```
geom_histogram(binwidth = 0.5, fill = "blue", color = "black") +
labs(title = "Distribution de la PM2.5",
     x = "PM2.5 (ug/m3)",
     y = "Fréquence") +
theme_minimal()
```

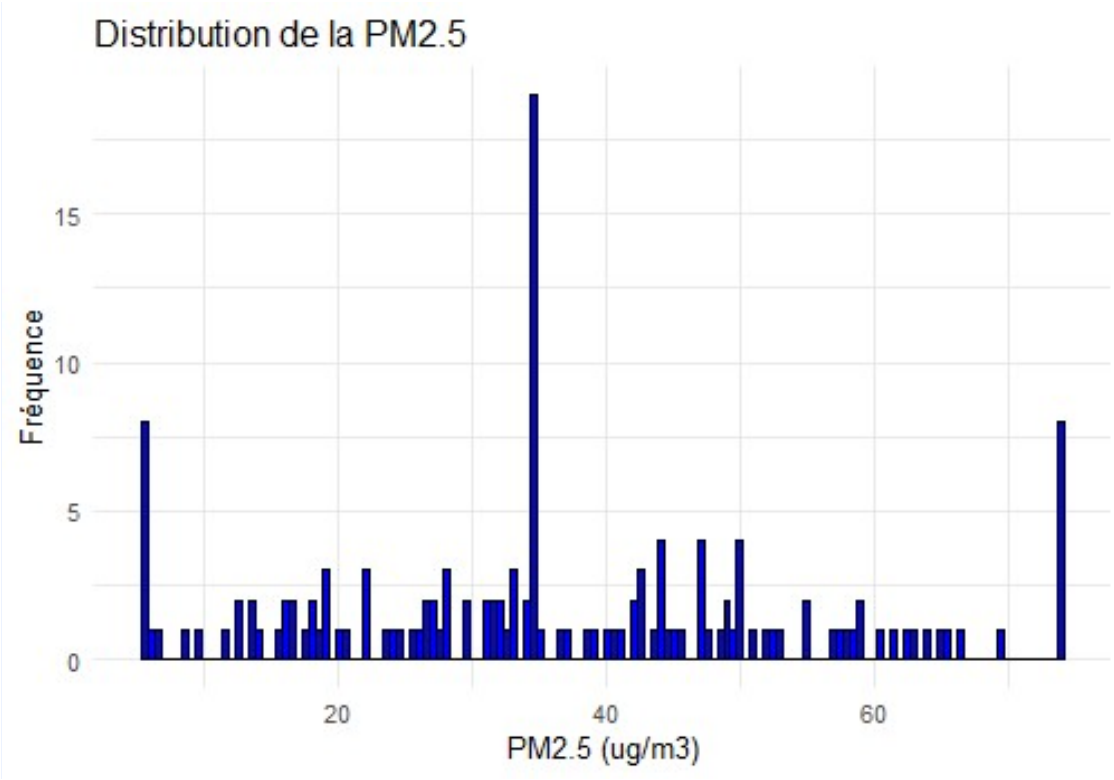


Commentaire : l'histogramme montre que la distribution n’est pas équilibrée : les fortes valeurs sont moins Nombreuses mais importantes.

la majorité des mesures sont plutôt faibles à modérées

La distribution des concentrations de PM2.5 montre une grande variabilité, avec une majorité des valeurs.

- ✓ Description bivariée et formulation d'une hypothése

Boxplot PM2.5 par Brulage de dechets

```
ggplot(df, aes(x = Brulage_dechets, y = PM25_ugm3, fill = Brulage_dechets)) +
  geom_boxplot() +
  labs(title = "PM2.5 selon le brulage de dechets",
       x = "Brulage de dechets",
       y = "PM2.5 (ug/m3)") +
  theme_minimal()
```

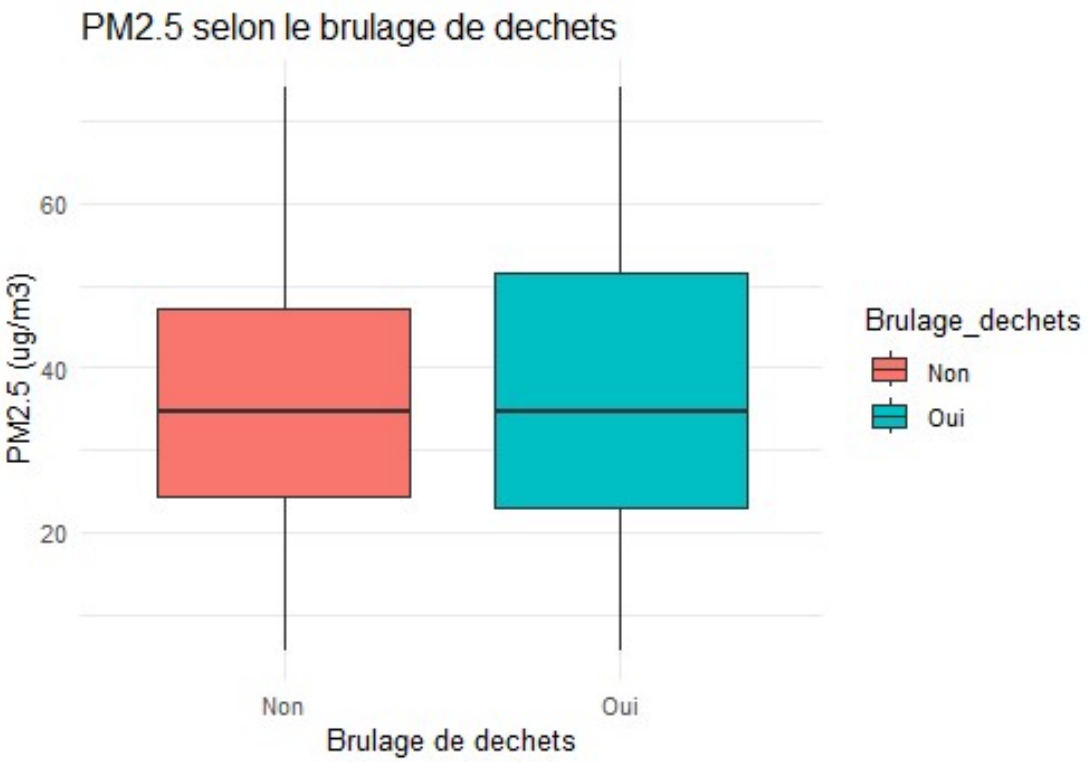


Commentaire : le Graphique montre une comparaison de PM2.5 en fonction de la présence ou non de brulage de déchets

La médiane des PM2.5 est plus élevée dans le groupe "Oui" (brûlage) que dans le groupe "Non". La boite est plus étendue que celle avec non brulage

la 3ieme Quartile pour brûlage est supérieur à celle de non brulage

Le graphique suggère une association entre la présence d'activités industrielles et la perception ou la mesure du bruit dans la zone étudiée

- ✓ Tests Statistiques

Test paramétrique (Test de **Student** et Test de **Welch**)

Conditions:

La variable quantitative est normalement distribuée dans chaque groupe.

Les variances des deux groupes sont égales.

Les  PM2.5 et brulage de dechets sont indépendantes.

NB: Le test de Student et le test de Welch ont les mémes hypothéses :

**H0** : les moyennes des deux groupes sont égales

**H1** : les moyennes des deux groupes ne sont pas égales

Vérification des hypothéses :

- Normalité globale (ou par groupe si on veut étre plus strict)

Test de **Shapiro-Wilk** pour la variable 'PM25_ugm3'

**H0**:p_value < = 0.05: normalité rejetée

**H1**: p_value > 0.05: normalité plausible

```
library(car)

shapiro_test_total <- shapiro.test(df$PM25_ugm3)

print(shapiro_test_total)
```

```
Shapiro-Wilk normality test

data:  df$PM25_ugm3
```

```
W = 0.97101, p-value = 0.003776
```

la p_value est inférieure à 0.05 Donc la normalité est rejeté

- On fait les test non paramétrique car y'a pas de normalité

Séparation des données par Brulage de dechets

```
brul_oui <- df$PM25_ugm3[df$Brulage_dechets == "Oui"]

brul_non  <- df$PM25_ugm3[df$Brulage_dechets == "Non"]
```

- Test de **Wilcoxon** pour deux échantillons indépendants

Conditions : Indépendance des échantillon, Pas besoin de normalité

**H0** : Les distributions des deux groupes sont égales.

**H1** :  Les distributions des deux groupes sont différentes

```
wilcoxon_test <- wilcox.test(brul_oui, brul_non)

print(wilcoxon_test)
```

```
Wilcoxon rank sum test with continuity correction

data:  brul_oui and brul_non
W = 2008.5, p-value = 0.6393
alternative hypothesis: true location shift is not eq
ual to 0
```

La p_value est supérieure à 0.05 . Donc  Les distributions des deux groupes sont égales

**Conclusion générale** : Le PM2.5 n'est pas différent quand il y a brûlage ou quand il y'a pas brûlage.

## 6) Quanti × Quali (2 groupes) : bruit et industrie

Le bruit est-il plus élevé en zone industrielle (oui/non) ?

❖ création de la colonne Industriel_oui_non à partir de Usage_sol

```
df$Industriel_oui_non <- ifelse(df$Usage_sol == "Industriel",
                                "Oui", "Non")
df$Industriel_oui_non <- factor(df$Industriel_oui_non)
```

❖ Description univariées des variables

Pour la variable qualitative 'Industriel_oui_non'

```
industriel_oui_non_table <- table(df$Industriel_oui_non)
industriel_oui_non_table
```

On a 120 non et 24 Oui

❖ Répartition par Industrie

```
barplot(industriel_oui_non_table,
        main = "Distribution des industries",
        xlab = "Industriel",
        ylab = "Fréquence")
```

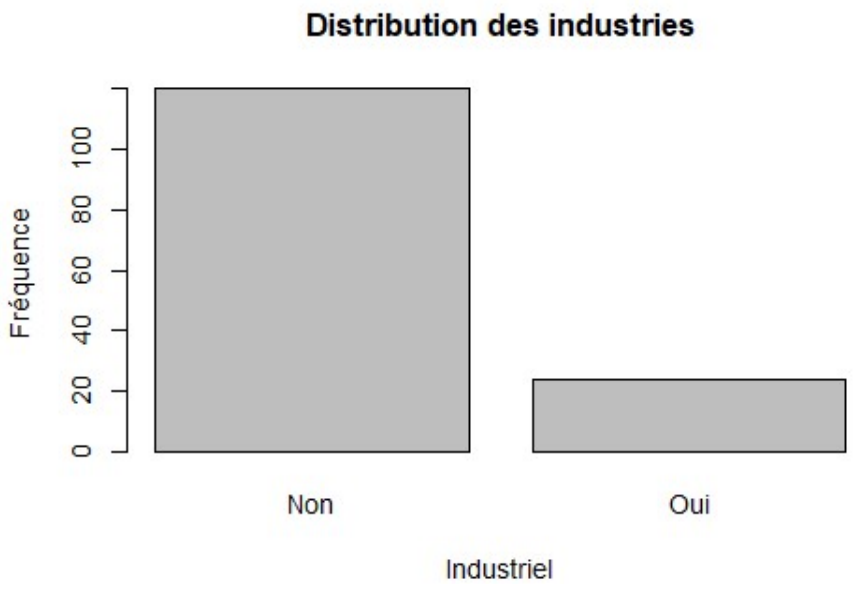

Commentaire :

La barre avec non Industriel est plus haut par rapport à la barre avec industriel

Donc industriel oui est minoritaire

La grande majorité des sites étudiés ne présentent pas d'activités industrielles

- ❖ Distribution de la variable quantitative 'Bruit_dB'

```
summary(df$Bruit_dB)
```

Commentaire :

Le Bruit_dB indique:

un minimum de 44,71dB , un maximum de 73,31 et une moyenne de 60.69dB

25% des valeurs sont inférieures ou égales à 55.61, 50% des valeurs sont inférieures ou égales à 61.88 et 75% des valeurs sont inférieures ou égales à 66.03

- ❖ Histogramme des PM2.5

```
ggplot(df, aes(x = Bruit_dB)) +
  geom_histogram(binwidth = 0.5, fill = "blue", color = "black") +
  labs(title = "Distribution de la Bruit",
       x = "Bruit ()",
       y = "Fréquence") +
  theme_minimal()
```

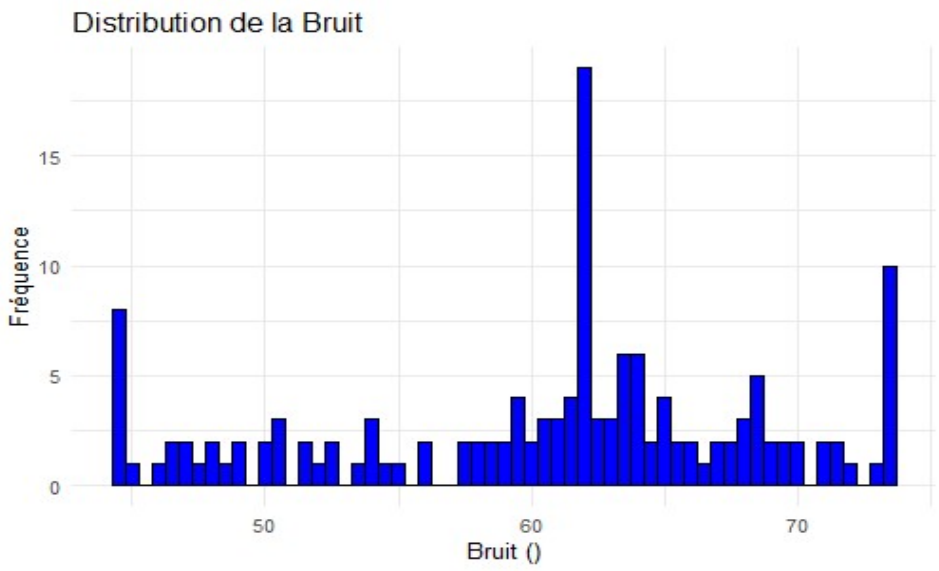

Commentaire : Ce graphique montre la répartition des niveaux de bruit observés. La majorité des mesures se concentre autour de 60–70 dB, indiquant un environnement généralement bruyant, avec quelques variations

Il existe quelques valeurs plus faibles et quelques plus élevées, mais elles sont moins nombreuses.

La distribution montre une variabilité modérée du bruit.

❖ Description bivariée et formulation d'une hypothése

Boxplot Bruit par Industrie

```
ggplot(df, aes(x = Industriel_oui_non, y = Bruit_dB, fill = Industriel_oui_non)) +
  geom_boxplot() +
  labs(title = "Bruit selon l'industrie",
       x = "Industriel",
       y = "Bruit") +
  theme_minimal()
```

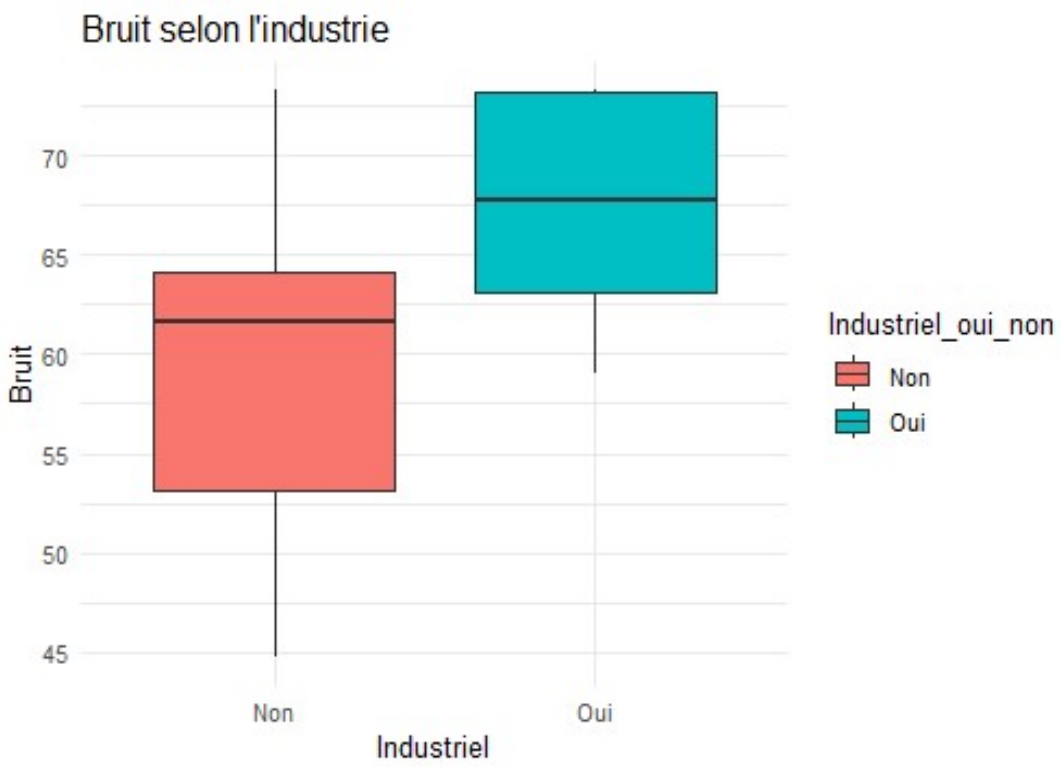

Commentaire : Ce diagramme en boîte montre une comparaison du bruit en fonction de la présence ou non d'industrie

Il montre que les zones avec industrie présentent des niveaux de bruit globalement plus élevés que les zones sans industrie. La médiane du bruit est plus haute en présence d'activités industrielles

Les zones avec industrie présentent une proportion beaucoup plus élevée de problèmes de bruit que les zones sans industrie.

- ❖ Tests Statistiques

Test paramétrique (Test de **Student** et Test de **Welch**)

Conditions:

les échantillons sont indépendants

La variable quantitative est normalement distribuée dans chaque groupe.

Les variances des deux groupes sont égales.

NB: Le test de **Student** et le test de Welch ont les mêmes hypothèses :

**H0** : les moyennes des deux groupes sont égales

**H1** : les moyennes des deux groupes ne sont pas égales

Vérification des hypothèses :

- Normalité globale (ou par groupe si on veut étre plus strict)

Test de **Shapiro-Wilk** pour la variable 'Bruit_dB'

**H0**:p_value < = 0.05: normalité rejetée

**H1**: p_value > 0.05: normalité plausible

library(car)

```
shapiro_test_total <- shapiro.test(df$Bruit_dB)

print(shapiro_test_total)
```

```
        Shapiro-Wilk normality test
data:  df$Bruit_dB
W = 0.94055, p-value = 8.687e-06
```

la p_value est inférieur à 0.05 Donc la normalité est rejeté

- ❖ On fait les test non paramétrique car y'a pas de normalité

Séparation des données par Brulage de déchets

```
indus_oui <- df$Bruit_dB[df$Industriel_oui_non == "Oui"]

indus_non  <- df$Bruit_dB[df$Industriel_oui_non == "Non"]
```

Test de **Wilcoxon** pour deux échantillons indépendants

Conditions :Indépendance des échantillon, Pas besoin de normalité

H0 : Les distributions des deux groupes sont égales.

H1 :  Les distributions des deux groupes sont différentes

```
wilcoxon_test <- wilcox.test(indus_oui, indus_non)

print(wilcoxon_test)
```

```
Wilcoxon rank sum test with continuity correction

data:  indus_oui and indus_non
W = 2323, p-value = 2.179e-06
alternative hypothesis: true location shift is not equal to 0
```

La p_value est inférieure à 0.05 . Donc  Les distributions des deux groupes sont différentes

**Conclusion générale** : Le bruit est plus élevé en zone industrielle oui qu'en zone industriel non

## 7) Quanti × Quali (>2 groupes) : ANOVA / Welch ANOVA / Kruskal–Wallis

Le bruit diffère-t-il selon le type de zone ?

- Description univariée

**Type_zone**

```
table_type <- table(df$Type_zone)

print(table_type)
```

Pour les Types de zone on a : 48 zone Périurbains, 36 zones Rurales et 60 zones Urbains

```
barplot(table_type,
        main = "Répartition des types de zone",
        xlab = "Type de zone",
        ylab = "Fréquence")
```

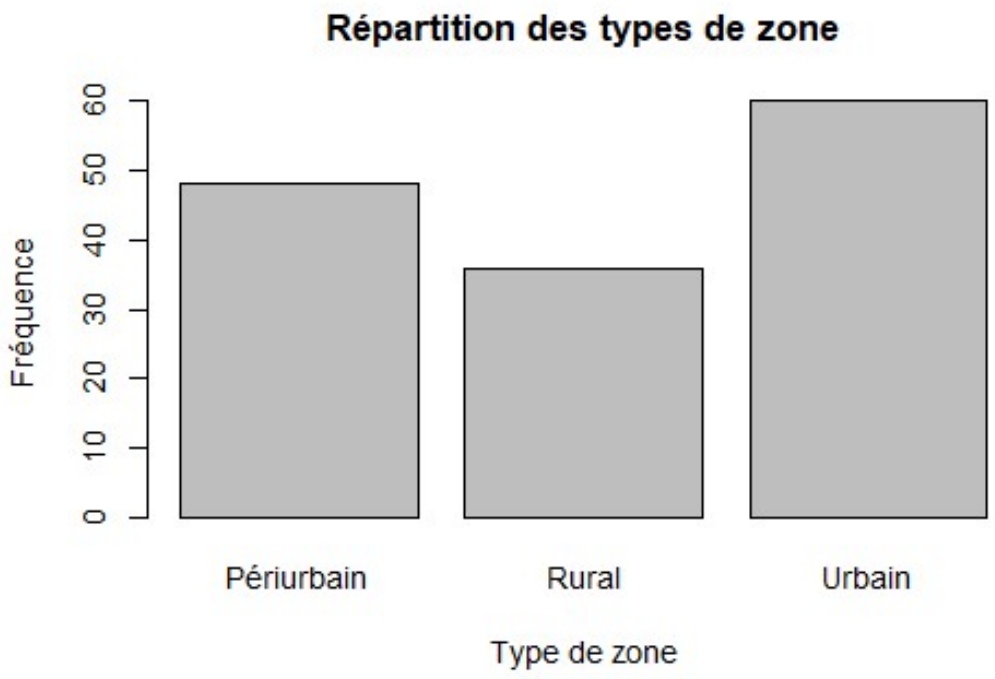

Commentaire : la répartition des types de zone est inégale : les zones urbaines sont plus fréquentes suivies des zones périurbaines et enfin les zones rurales sont moins représentées

**Bruit_dB**

summary(df$Bruit_dB)

Le Bruit_dB indique:

un minimum de 44,71dB , un maximum de 73,31 et une moyenne de 60.69dB

25% des valeurs sont inférieures ou égales à 55.61, 50% des valeurs sont inférieures ou égales à 61.88 et 25% des valeurs sont inférieures ou égales à 66.03

```
hist(df$Bruit_dB,
    main = "Distribution du bruit",
    xlab = "Bruit (dB)",
    col = "skyblue",
    border = "black")
```

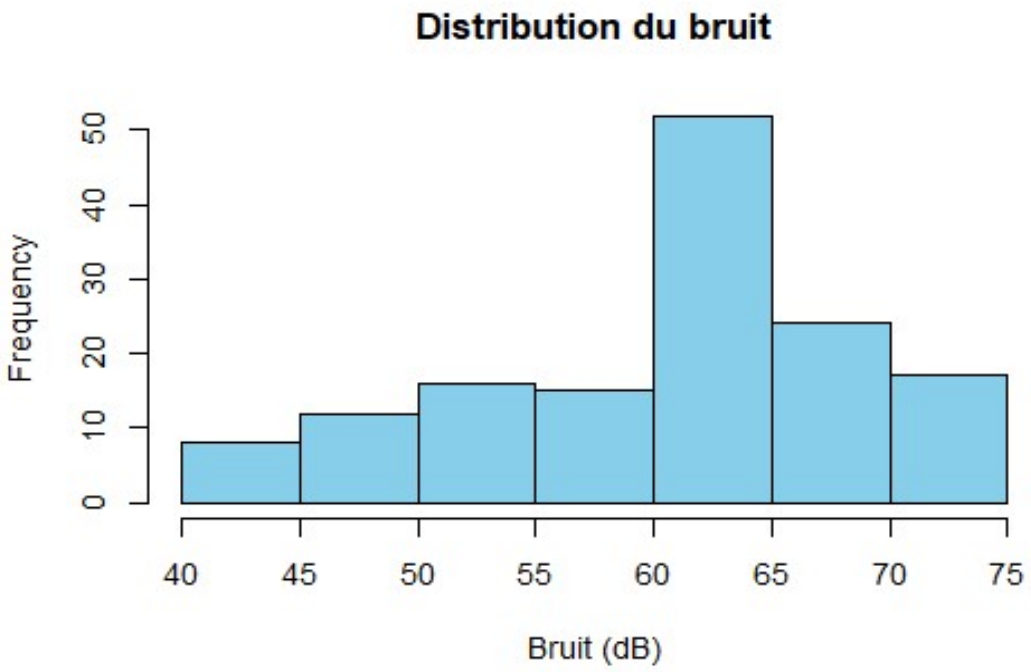

commentaire : l'histogramme montre que la distribution du bruit est concentrée autour de 60 à 65 dB et a aussi plus de valeurs vers les faibles bruits. Ce type de distribution aide à comprendre à quel point un lieu est bruyant

- Description bivariée

Boxplot Bruit x Type de zone

```
ggplot(df, aes(x = Type_zone, y = Bruit_dB, fill = Type_zone)) +
  geom_boxplot() +
  labs(title = "Bruit selon le type de zone",
       x = "Type de zone",
       y = "Bruit (dB)") +
  theme_minimal()
```

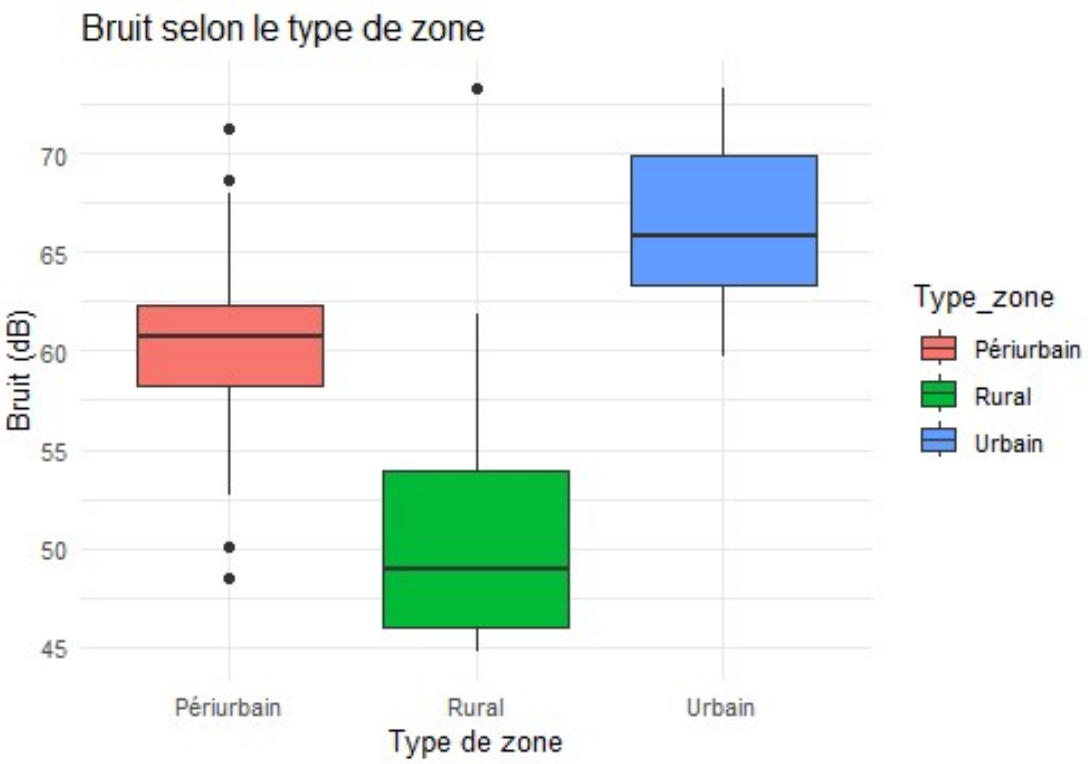


Commentaire : Le bruit max est le plus élevé en urbain, tandis que le min et la médiane augmentent du rural à l'urbain.

Les zones urbaines sont naturellement plus bruyantes en raison de la densité de population, des activités

Les zones périurbaines représentent moins de bruit

Les zones rurales  avec un faible bruit

Le graphique confirme que le type de zone d'habitation influence le bruit

- Tests statistiques

Vérification de la normalité par test de **shapiro**

**H0** : p_value < = 0.05: normalité rejetée

**H1** : p_value > 0.05: normalité plausible

shapiro.test(df$Bruit_dB)

```
Shapiro-Wilk normality test

data:  df$Bruit_dB
W = 0.94055, p-value = 8.687e-06
```

La p_value est inférieure à 0.05 Donc la normalité est rejetée

- Donc on applique le test de Kruskal-Walli car ce n'est pas paramétrique (pas de normalité)

Conditions : groupes indépendants, K >= 3 groupes, pas de normalité

**H0**: les k populations ont la même distribution ou les médianes des groupes sont égales.

**H1**: au moins un groupe a une distribution différente.

kruskal_test <- kruskal.test(Bruit_dB ~ Type_zone, data = df)

print(kruskal_test)

```
 Kruskal-Wallis rank sum test

data:  Bruit_dB by Type_zone

Kruskal-Wallis chi-squared = 79.665, df = 2, p-value < 2.2e-16
```

La p_value est inférieure à 0.05, Donc au moins un groupe a une distribution dif férente. Donc il existe une différence statistiquement significative entre les dist ributions de bruit des trois zones (urbain, périurbain, rural).

En d'autres termes, au moins une zone a un niveau de bruit médiane différent des autres.

**Conclusion générale** : Le bruit diffère significativement selon le type de zone

**8) Quanti × Quali (>2 groupes)**

Le PM2.5 diffère-t-il selon l'usage du sol ?

- ❖ Description univariée

**Usage_sol**

```
table_alt <- table(df$Usage_sol)

print(table_alt)
```

Pour l'Usage_sol on a 60 Agricole 24 Industriel 24 Mixte et 36 Résidentiel

```
barplot(table_alt,
        main = "Répartition des Usage de sol",
        xlab = "Usage de sol",
        ylab = "Fréquence")
```

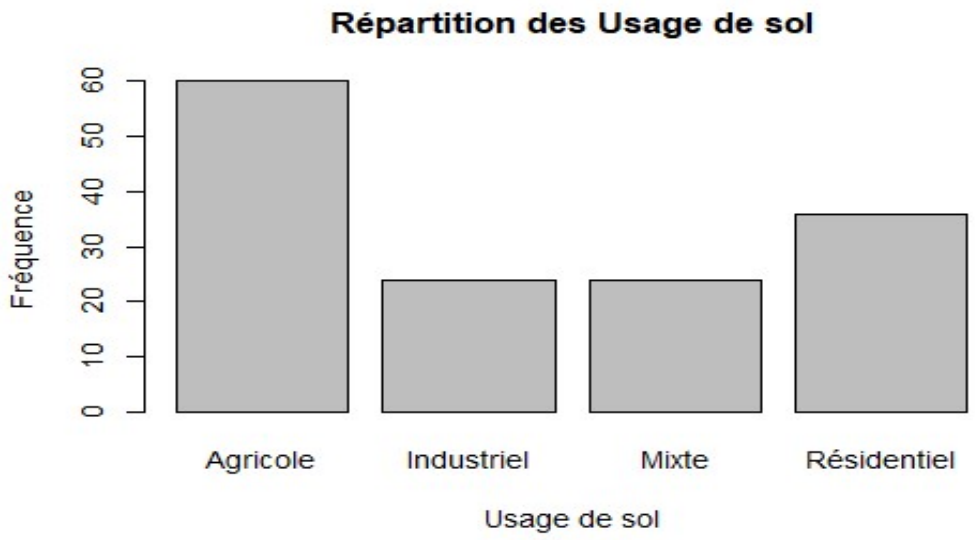

Commentaire : Ce graphique présente la répartition fréquentielle des différents types d'usage de sol dans une zone d'étude.

L’usage agricole est le plus fréquent, suivi par le résidentiel, puis les usages industriel et mixte qui sont similaires et moins importants

Dans la zone d'étude, l'usage du sol est dominé par les zones agricoles, qui représentent la majorité des sites. Les zones résidentielles viennent ensuite, tandis que les zones industrielles et agricole sont relativement rares

**PM25_ugm3**

```
summary(df$PM25_ugm3)
```

le PM25_ugm3 indique:

un minimum de 5.466ug/m3 , un maximum de 74,03 et une moyenne de 36.506ug/m3

25% des valeurs sont inférieures ou égales à 23.777, 50% des valeurs sont inférieures ou égales à 34.597 et 75% des valeurs sont inférieures ou égales à 48.560

```
hist(df$PM25_ugm3,
    main = "Distribution du PM2.5",
    xlab = "PM2.5 (ugm3)",
    col = "skyblue",
    border = "black")
```

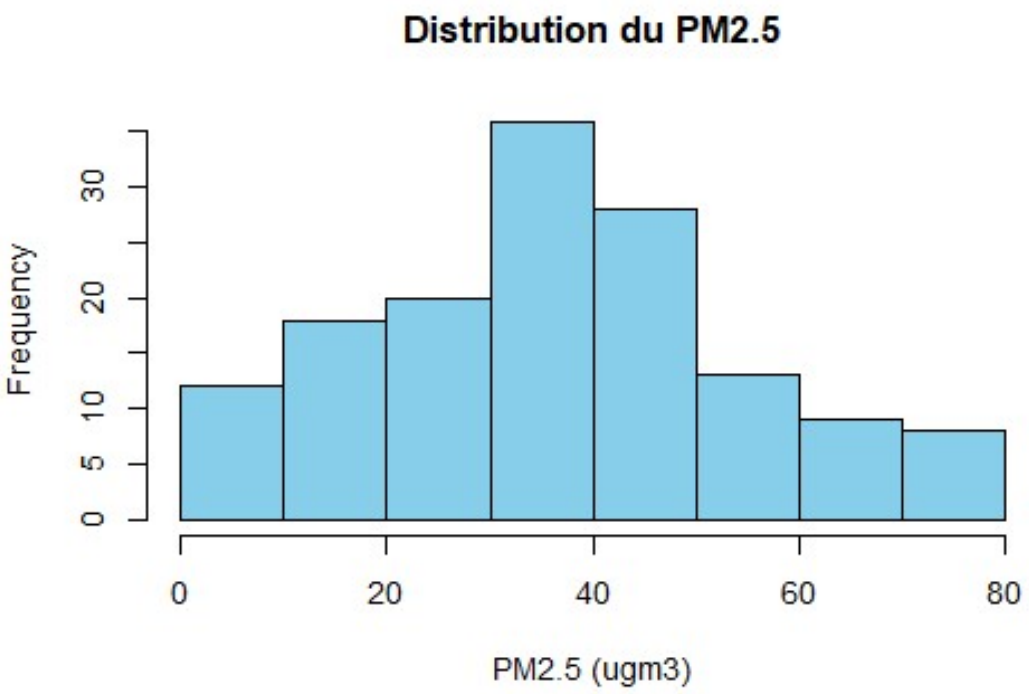


Commentaire : Ce graphique présente la distribution de la concentration de PM2.5. Le graphique montre que la distribution du PM2.5 est maximale dans l'intervalle 30-50. La distribution semble asymétrique avec une fréquence élevée pour les valeurs moyennes (0-30) et des valeurs extrêmes moins fréquentes

❖ Description bivariée

Boxplot Bruit x Type de zone

```
ggplot(df, aes(x = Usage_sol, y = PM25_ugm3, fill = Usage_sol)) +
  geom_boxplot() +
  labs(title = "PM2.5 selon l'Usage de sol",
       x = "Usage de sol",
       y = "PM2.5(ugm3)") +
  theme_minimal()
```

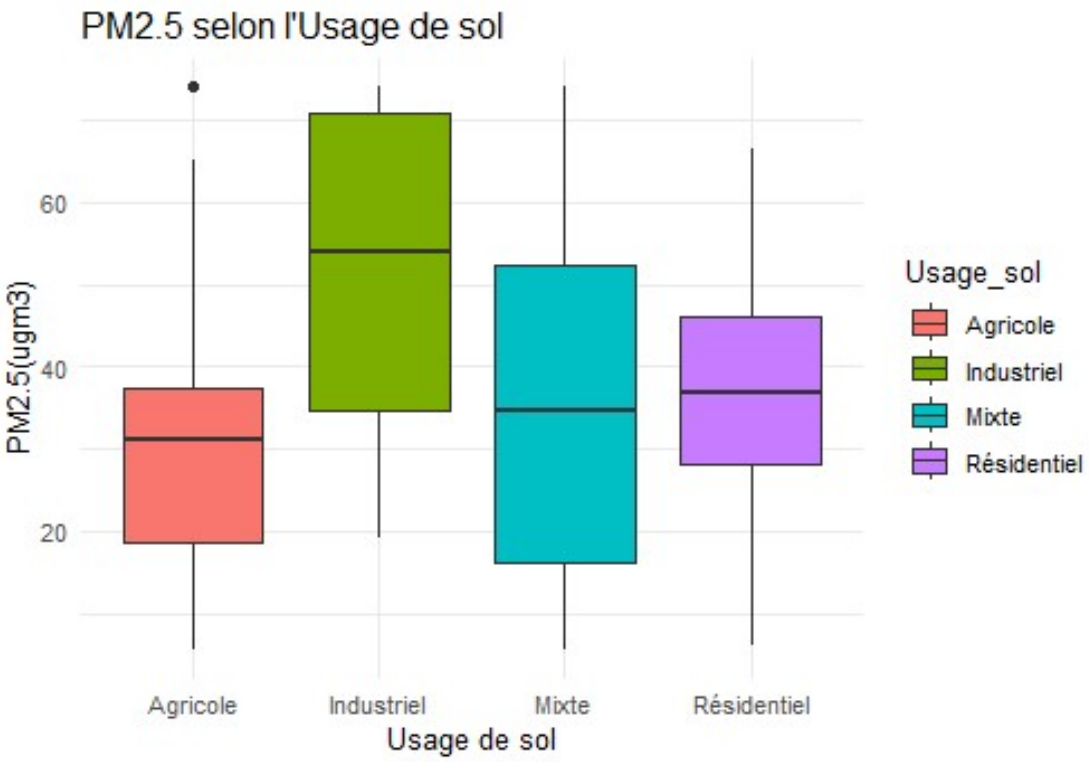


Commentaire : Ce graphique présente la concentration de PM2.5 (en µg/m³) selon l'usage du sol.

Usage industriel : Concentrations de PM2.5 les plus élevées (médiane la plus haute).

Usage mixte : Niveaux de PM2.5 élevés mais inférieurs à l'industriel.

Usage résidentiel : avec une Concentrations modérées

Usage agricole : avec les concentrations les plus basses

- ❖ Tests statistiques

Vérification de la normalité par test de **shapiro**

H0:p_value < = 0.05: normalité rejetée

H1: p_value > 0.05: normalité plausible

shapiro.test(df$PM25_ugm3)

```
        Shapiro-Wilk normality test

data:  df$PM25_ugm3
W = 0.97101, p-value = 0.003776
```

La p_value est inférieure à 0.05 Donc la normalité est rejetée

- Donc on applique le test de Kruskal-Walli car ce n'est pas paramétrique ( pas de normalité)
- Conditions : Groupes indépendants, K >= 3 groupes, pas de normalité

H0: les k populations ont la même distribution ou les médianes des groupes so nt égales.

H1: au moins un groupe a une distribution différente.

kruskal_test <- kruskal.test(PM25_ugm3 ~ Usage_sol, data = df)

print(kruskal_test)

La p_value est inférieure à 0.05, Donc au moins un groupe a une distribution dif férente. PM2.5 diffèrent significativement selon l'usage du sol.

Le type d'usage du sol influence bien les niveaux de PM2.5

**Conclusion générale** : Le PM2.5 diffère selon l'usage du sol

9) Ordinale × Ordinale : Tau de Kendall (ou Spearman)

La perception de la qualité de l'air est-elle liée à la gêne du bruit ?

Méthode

Corrélations ordinales : **Spearman & Kendall**

**Tau de Kendall**

Conditions :

Les variables sont ordinales, les deux sont indépendants

len_perception <- length(df$Perception_air_1a5)

len_bruit <- length(df$Gene_bruit_1a5)

print(len_bruit)

```
[1] 144
```

```
print(len_perception)
[1] 144
```

Après vérification, la Taille d’échantillon est modérée

H0: il n’existe aucune association monotone entre La perception de la qualité d

e l’air et le gêne du bruit

H1: il existe une association monotone.

Dans ce cas on doit transformer en valeurs

numériques ordonnées les deux variables qualitatives ordinales

```
df$Perception_air_1a5 <- factor(
  df$Perception_air_1a5,
  levels = 1:5,
  ordered = TRUE
)

df$Gene_bruit_1a5 <- factor(
  df$Gene_bruit_1a5,
  levels = 1:5,
  ordered = TRUE
)
Perc <- as.numeric(df$Perception_air_1a5)
Gen <- as.numeric(df$Gene_bruit_1a5)
df
kendall_test  <- cor.test(Perc, Gen, method = "kendall", use = "complete.obs")
print(kendall_test)
Kendall's rank correlation tau

data:  Perc and Gen
z = -2.7628, p-value = 0.005732
alternative hypothesis: true tau is not equal to 0
```

```
sample estimates:
       tau
-0.2020962
```

la p_value est inférieur à 0.05 Donc Il existe une association monotone entre La perception de la qualité de l'air et le gêne du bruit

D'après le Tau de Kendall il existe une association négative parfaite ($\tau = -0.202$, $p < 0.05$) entre la perception de la qualité de l'air et la gêne du bruit.

Quand Perception air augmente (1mauvais→5bon)

Alors Gêne bruit diminue (5forte→1faible)

Conclusion générale: Oui, la perception de la qualité de l'air est liée à la gêne d u bruit.

## 10) Données appariées : t apparié / Wilcoxon signé

Uniquement sur la campagne poussière (Campagne == "Campagne_poussiere")

La campagne a-t-elle réduit PM2.5 ?

- Campagne poussière

```
df_campagne <- df[df$Campagne == "Campagne_poussiere", ]
```

- Valeurs Avant et Après

```
df_paire <- df_campagne %>%
  select(Station, Phase_intervention, PM25_ugm3) %>%
  pivot_wider(names_from = Phase_intervention,
   values_from = PM25_ugm3) %>%
  na.omit()
```

- Différences

```
df_paire$difference <- df_paire$Après - df_paire$Avant
```

- summary(df_paire$difference)

Commentaire :

La différence (Après − Avant) de PM2.5 est globalement négative.

La médiane est de −10.2 µg/m³, indiquant qu'au moins la moitié des stations ont enregistré une baisse d'environ 10 µg/m³.

La moyenne (−9.0 µg/m³) confirme une diminution globale après la campag ne.

Les quantiles montrent que 75 % des stations ont une baisse d'au moins 2 µ g/m³, tandis que 25 % ont une baisse supérieure à 15 µg/m³.

Les valeurs extrêmes vont d'une diminution maximale de −31.9 µg/m³ à une augmentation maximale de +17.0 µg/m³.

❖ Visualisation

```
ggplot(df_paire, aes(x = difference)) +
  geom_histogram(fill = "purple", color = "white") +
  geom_vline(xintercept = 0, color = "red", linewidth = 1) +
  labs(title = "Histogramme de la différence PM2.5 (Après - Avant)",
       x = "Différence PM2.5 (µg/m³)",
       y = "Fréquence") +
  theme_minimal()
```

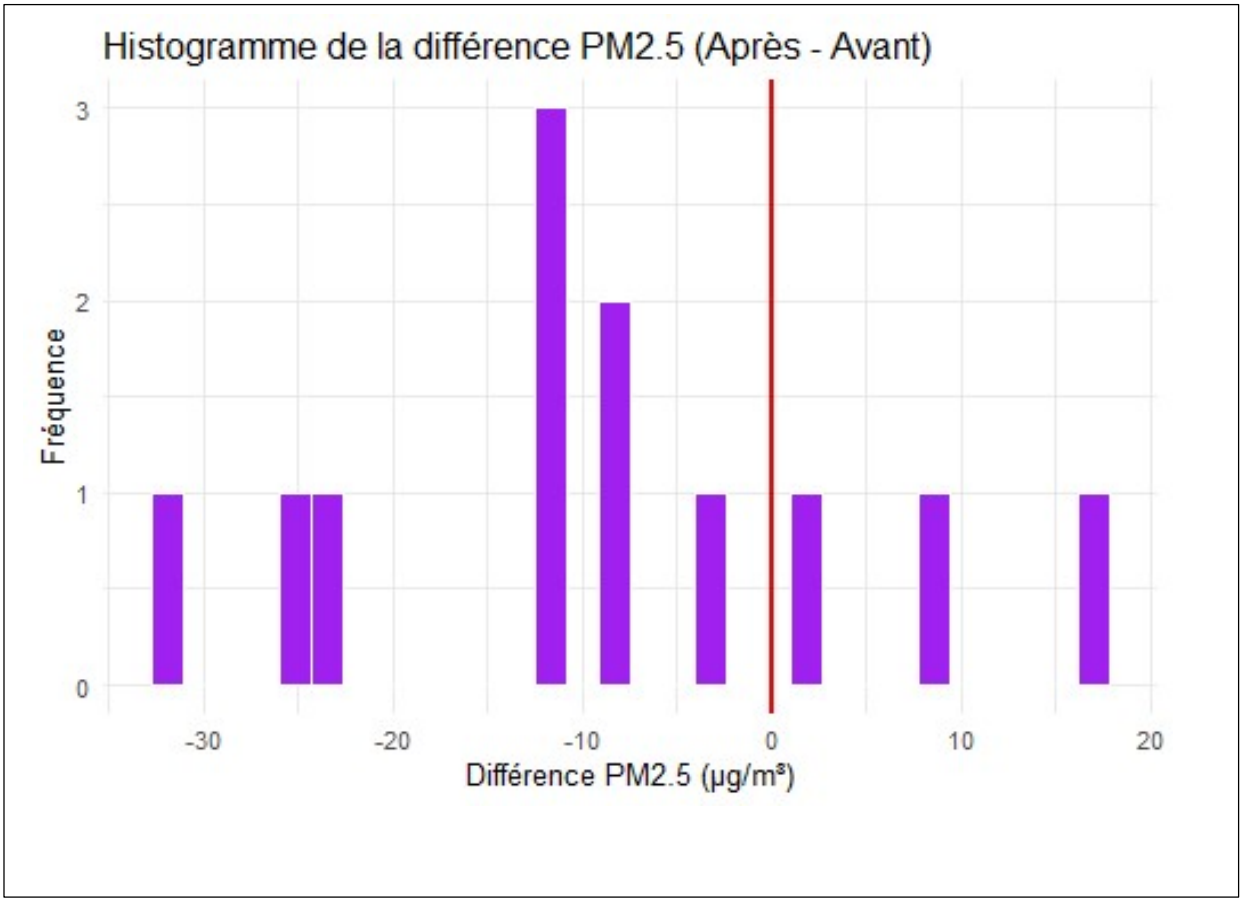

Commentaire :

L'histogramme montre une distribution symétrique des différences PM2.5 autour de 0 (-30 à +20 µg/m³), suggérant que la campagne n'a pas eu d'effet moyen significatif : les réductions et augmentations se compensent. Certaines stations ont diminué tandis que d'autres ont vu une augmentation, indiquant une forte variabilité

- ❖ Vérification de la normalité

H0:p_value < = 0.05: normalité rejetée

H1: p_value > 0.05: normalité plausible

shapiro.test(difference)

```
Shapiro-Wilk normality test

data:  difference
W = 0.97152, p-value = 0.9261
```

la p_value est supérieure à 0.05 Donc il y'a normalité

- ❖ Test apparié

#Test de **Student**

**H0** : Les moyennes des deux groupes sont égales.

**H1** :  Les moyennes des deux groupes sont différentes.

test_final = t.test(apres, avant, data = df, paired = TRUE)

sprint(test_final)

```
      Paired t-test

data:  apres and avant
t = -2.2221, df = 11, p-value = 0.04819
alternative hypothesis: true mean difference is not e
qual to 0
95 percent confidence interval:
 -17.98141977  -0.08580579
```

```
sample estimates:
mean difference
      -9.033613
```

La p_value est inférieure à 0.05; donc Les moyennes avant et apres sont différe ntes

Le test t apparié révèle une réduction significative des concentrations de PM2.5 suite à la campagne d'intervention

**Conclusion générale** : Oui, La campagne a réduit PM2.5

# CONCLUSION

Cette étude met en évidence des différences significatives de qualité de l'air et de bruit selon le type de zone et l'usage du sol à Thiès. Les zones urbaines et industrielles apparaissent comme les plus exposées aux fortes concentrations de PM2.5 et aux niveaux de bruit élevés, notamment en présence de brûlage de déchets. Par ailleurs, la végétation (NDVI) joue un rôle protecteur, avec des niveaux de pollution généralement plus faibles dans les zones plus végétalisées.

# RECOMMANDATIONS

En conséquence, il est recommandé de renforcer la surveillance environnementale dans les zones urbaines et industrielles, de limiter le brûlage de déchets par des actions de sensibilisation et de contrôle, et de promouvoir la végétalisation urbaine comme solution durable pour améliorer la qualité de l'air et le confort environnemental. Ces mesures contribueraient à une meilleure gestion du cadre de vie et à la réduction des risques pour la santé des populations.